

清 华 大 学

综 合 论 文 训 练

题目：基于神经网络的富语境关系自
动抽取：一种新型的单语句编
码器

系 别：理学院物理系

专 业：数理基础科学

姓 名：唐路明

指导教师：刘知远 副教授

2018 年 6 月 13 日

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：学校有权保留学位论文的复印件，允许该论文被查阅和借阅；学校可以公布该论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存该论文。

(涉密的学位论文在解密后应遵守此规定)

签 名：_____ 导师签名：_____ 日 期：_____

中文摘要

作为构建高质量知识图谱的关键步骤，关系抽取的任务目标是从无标注的原始文本数据中抽取结构化信息与知识。随着深度学习的发展，基于神经网络的关系抽取系统也获得了很大的成功。本文对神经关系抽取领域进行了综述，并自主实现了数个主流模型作为基线。

然而针对文本语句过长的情况，如何在尽可能多地保留重要局部特征的前提下给出语句的向量化表示，仍是一个值得探讨的问题。为了解决这一问题，本文提出了一种新型的面向关系抽取的单语句编码器 RE_NetVLAD (Vector of Locally Aggregated Descriptors for Relation Extraction) 来学习单语句的向量表示。与基线模型相比，RE_NetVLAD 在一个公开的大规模关系抽取数据集上取得了最好的单模型效果，且在不同的设定下，RE_NetVLAD 都可以在训练效率和抽取效果上给出稳定的极有竞争力的表现。实验证明，RE_NetVLAD 对于语句的长度和自身的超参数设置有很强的鲁棒性，而且模型内部的聚类操作在有监督学习下表现出了可解释性的语言学意义。

关键词：关系抽取；神经网络；知识图谱

ABSTRACT

As a key step in building a high-quality knowledge graph, the goal of relation extraction is to extract structured information and knowledge from unlabeled raw text data. With the development of deep learning, neural network based relation extraction system has achieved a great success. We give a review on the neural relation extraction area and implement several state-of-the-art models from scratch as the baseline.

However, for the case of rich context, how to represent the whole sentence with one vector while retaining as many local features as possible, still remains unsolved. In order to solve this problem, we propose a new sentence encoder for relation extraction, RE_NetVLAD (Vector of Locally Aggregated Descriptors for Relation Extraction) to learn the representation of the single sentence. RE_NetVLAD has achieved the best performance on a large-scale public relation extraction dataset, and it could also give a stable and competitive performance on training efficiency and extraction results. Experiments show that RE_NetVLAD has strong robustness to the length of the sentence as well as its own hyperparameter settings. The clustering operation inside the model shows an interpretable linguistic meaning under the supervised learning setting.

Keywords: Relation Extraction; Neural Network; Knowledge Graph

目 录

第 1 章 引言	1
1.1 知识图谱	1
1.1.1 基础概念	1
1.1.2 典型实例	2
1.2 关系抽取	3
1.2.1 基于人工特征的关系抽取	3
1.2.2 远程监督	3
1.2.3 基于神经网络的关系抽取	4
1.3 论文贡献	4
第 2 章 基于神经网络的关系抽取方法综述	6
2.1 单语句关系抽取	6
2.1.1 输入编码器	7
2.1.2 单语句编码器	7
2.1.3 关系分类器	12
2.2 多语句关系抽取（篇章级关系抽取）	12
2.2.1 多语句编码器	13
第 3 章 RE_NetVLAD：一种新型可学习池化的单语句编码器	15
3.1 基于传统特征的计算机视觉中的 VLAD 方法	15
3.2 基于深度学习的计算机视觉中的 NetVLAD 方法	16
3.3 可学习池化的单语句编码器 RE_NetVLAD	18
第 4 章 实验结果与分析	20
4.1 数据集与评测指标	20
4.2 RE_NetVLAD 与基线模型的效果对比	20
4.3 模型的鲁棒性验证	26
4.3.1 单语句长度	26
4.3.2 聚类中心数目	29
4.4 聚类的语言学意义探索	30

第 5 章 文章结论与未来工作	32
参考文献	33
致 谢	36
声 明	37
插图索引	38
表格索引	40
公式索引	41
附录 A 外文资料的书面翻译	43
A.1 引言	43
A.2 相关研究工作	45
A.3 方法	46
A.3.1 语句编码器	47
A.3.2 面向多实例的注意力机制.....	49
A.3.3 优化方法与实现细节	50
A.4 实验部分	51
A.4.1 数据集和评测指标	51
A.4.2 实验设置	52
A.4.3 语句级别选择性注意力机制的有效性验证	53
A.4.4 语句数量的影响.....	54
A.4.5 与基于人工特征的方法的比较	54
A.4.6 案例分析	55
A.5 结论与未来工作.....	55
参考文献	59

主要符号对照表

x	输入单语句
m	单语句单词数目
e_1	头部实体
e_2	尾部实体
θ	神经网络的可学习参数
r	关系类型
$\mathbf{R}$	关系类型集合
$\mathbf{w}$	单语句输入的向量表示
$\mathbf{W}$	卷积核矩阵
$\mathbf{b}$	卷积核偏置
$\mathbf{x}$	单语句的向量化表示
$\mathbf{S}$	多语句集合的向量化表示
$\mathbf{M}$	关系矩阵
K	VLAD 内聚类中心数目

第 1 章 引言

本章主要介绍了如下三部分内容，第一部分对知识图谱的背景进行了简要的介绍，第二部分介绍了关系抽取任务并回顾了其主要相关工作，第三部分介绍了本文的主要贡献，最后陈述了整个论文的文章结构组成。

1.1 知识图谱

随着 21 世纪互联网的蓬勃发展，网络信息量呈爆炸性增长趋势。人们发现，从巨大的嘈杂文本中提取有价值的信息，或者更准确地说，知识 (knowledge)，变得越来越难。然后人们开始意识到，世界是由实体而不是字符串组成，就像 Google 的辛哈尔博士所说，“things, not strings (事物，而不是字符串)”。因此，知识图谱的概念逐渐进入了公众的视野。

知识图谱 (Knowledge Graph, KG)，也被称为知识库，是一个以结构化形式来组织有关世界的人类知识的重要数据库，其中知识被表示为具体实体以及它们之间多种的抽象关系概念。在构建知识图谱时，主要有两种方法。一种是在人工标注的帮助下，在资源描述框架 (Resource Description Framework, RDF) 中使用现有的含有具体语义的网页数据集。另一种是使用机器学习或深度学习方法，从互联网上的大量的无标注原始文本中自动抽取知识。

得益于这种结构良好的统一化知识表示，知识图谱可以有效提供关于我们所处的复杂现实世界的实用的结构化信息。因此，近年来它开始在许多人工智能应用中发挥重要作用，特别是在自然语言处理和信息检索领域如网页搜索，问答系统，语音识别等领域，引起了学术界和工业界的广泛关注。

1.1.1 基础概念

一个典型的知识图谱通常由两个要素组成，即实体 (包括具体实体和现实世界中的抽象概念) 以及实体之间的关系。因此，它以 $(e_1, relation, e_2)$ 的形式将各种知识排列成大量的三元组，其中 e_1 表示头部实体， e_2 表示尾部实体。例如，我们知道 *Donald Trump* 是 *United States* 的总统。这个知识可以被表示为 $(Donald Trump, president_of, United States)$ 。此外，值得注意的是，在现实世界中，同一个头部实体和关系可能对应数个不同的尾部实体。例如，*Kaká* 曾经为 *Real Madrid*

和 *A.C. Milan* 足球俱乐部都效力过。我们可以从这个知识中得到如下的两个三元组, (*Kaká*, *player_of_team*, *Real Madrid FC*), (*Kaká*, *player_of_team*, *A.C. Milan*)。同样的, 当尾部实体和关系类型固定时, 这种情况也会发生。头部和尾部实体也有可能都是多个 (例如, 关系类型 *writer_of_paper*)。通过这些三元组, 知识图谱可以表示为一张巨大的有向图, 其中的节点即为实体, 边即为实体间的关系。

1.1.2 典型实例

目前的知识图谱可以从能力和知识领域的角度分为两大类。第一类图谱中包含大量的三元组和众所周知的关系类型, 如 **Freebase**。第二类图谱相对较小, 但侧重于特定的知识领域例如医学、军事等, 通常更加细化。如下两个知名的知识图谱在应用程序中被广泛使用, 具有很大的影响力。

第一个是 **Freebase**, 世界上最流行的知识图谱之一。它是一个主要由其社区成员共享的数据组成的大型协作性数据库。它在线上整合了来自各种渠道的信息, 包括维基百科以及个人用户的提交, 并将其变成了结构化的数据。它还宣布为其用户提供开放的 **API**, **RDF** 端点和数据集转储, 用于商业和非商业用途。**Freebase** 由美国软件公司 **Metaweb** 开发, 并于 2007 年 3 月开始公开运行。2010 年 7 月, **Metaweb** 被 **Google** 收购, **Freebase** 也相应地合并成为 **Google** 的知识图谱。2014 年 12 月, 它正式宣布 **Freebase** 网站会在 2015 年 6 月前与其 **API** 一起关闭。截至到 2016 年 3 月 24 日, **Freebase** 总共整合了 58,726,427 个主题和 3,197,653,841 个关系事实。

第二个是 **Wikidata**, 一个由维基媒体基金会运营的协作编辑的知识图谱项目。它旨在提供一个可以被维基媒体项目 (例如维基百科) 以及其他个人用户使用的通用数据源。该项目的创建得到了艾伦人工智能研究所, 戈登和贝蒂摩尔基金会以及谷歌公司的捐赠, 总计 130 万欧元。至于内部的详细结构, **Wikidata** 是一个面向文档的数据库, 每个项目代表一个主题并由唯一编号标识。个人用户通过创建语句, 就可以将信息添加到项目中。语句采用键值对的形式, 每个语句由一个属性和一个链接到属性的值组成。截至 2018 年 5 月, 知识库包含 48,799,219 个任何人都可以编辑的数据项。

1.2 关系抽取

为了扩充现有的知识图谱，研究者们投入了很多精力去探索如何自动的发现未知的关系事实，这也被称为关系抽取任务，其目标是从未经标注的原始文本中抽取出结构化的关系事实和数据，是自然语言处理中的一个重要任务与研究领域。下面简要回顾三类重要的工作：

1.2.1 基于人工特征的关系抽取

最早的可实际应用的关系抽取方法是基于人工特征的统计机器学习模型^[1-3]。它首先使用人工设计的语义学特征对原始文本进行处理，例如词性分布、主谓关系、语法解析树结构等，从而得到含有原始文本语言学信息的较高维度的特征向量。在对数据进行人工标注后，采用传统的有监督的统计机器学习模型如支持向量机^[4]、概率图模型^[5] 等对特征向量进行分类，从而得到最终预测的关系类别。

然而这类方法面临着如下两个问题，第一个是人工标注需要耗费大量的人力物力，而有监督的机器学习模型的最终效果在很大程度上依赖于大规模的高质量的有标签数据。如何减少获取有标签数据的难度从而充分利用互联网上无穷无尽的无标签原始文本数据，成为了一个重要问题。第二个问题是，通常情况下，人工设计的语义学特征，很多时候难以完整全面地表达原始文本的语义内容，同时这些语义学特征的获取也依赖于各种现有的自然语言处理工具，而这些工具本身也有着标注不准确的问题，这样一来，标注错误就会通过获取的语义学特征传递和叠加到关系抽取任务上。因此，问题的关键在于如何获取高质量的原始文本的特征向量表示。接下来两部分要介绍的远程监督和神经网络模型分别在一定程度上很好地解决了这两个问题。

1.2.2 远程监督

真正意义上应用于关系抽取中的远程监督方法最早由^[2] 提出，它将无标注的原始文本与现有的知识图谱 **Freebase** 数据库中的实体对和关系类型进行了语料对齐，从而未经人工标注地自动构建了一个大规模的有标签的关系抽取数据集，大大降低了获取数据的难度和成本，使得大规模有监督学习成为可能。由于同一实体对可能同时出现在多个文本语句中，而且还有着多重的关系类型，即同一个训练样例可能对应着多重的训练数据与多重的标签，因此^[1,3] 引入了多样例多标签学习的机制，在^[2] 提出的数据集上建立了最初的基线模型和评测方法。

但是远程监督也有着自己的问题，由于在进行语料对齐时，它默认了所有包含目标实体对的文本语句都可以表示知识图谱中目标实体对所对应的关系类型。但实际上，很多时候语句本身仅仅是包含了目标实体对，而并没有在语义上表达实体间的关系，或者表达的是其他关系类型而非目标关系类型，从而不可避免地带来了错误标注的问题。如何进一步增加远程监督的准确性^[6]，以及减少错误数据带来的噪音^[7]，成为之后很多工作探讨的主题。

1.2.3 基于神经网络的关系抽取

随着深度学习在计算机视觉^[8]、语音识别^[9]等任务上取得一系列突破性进展，神经网络模型也逐渐开始在自然语言处理领域被广泛应用，例如机器翻译^[10]、对话系统^[11]等。相较于传统的人工特征，神经网络可以通过有监督学习的方式，自主地学习数据的向量化表示，同时还可进行端到端的训练和预测。由于其显著的表示学习特点可以有效弥补人工特征的局限性，基于神经网络的模型与方法逐渐成为了关系抽取领域的主流：^[12] 最早将递归神经网络（Recursive Neural Network, RNN）应用到关系抽取任务上，之后^[13] 采用了两种不同的卷积神经网络（Convolution Neural Network, CNN）；^[14] 使用了长短时记忆模型（Long Short-Term Memory network, LSTM）；^[15] 将传统的语法树与 LSTM 相结合，两者在表示上相互补充；^[7] 采用了神经网络中常用的注意力机制（Attention Model）；^[16] 应用残差网络（Residual Connection）进一步了改进 CNN 等，这些都在不同程度上展现了深度学习方法的优势。在第二章中对神经关系抽取系统的综述中，会有选择性的对上述模型进行具体介绍。

以上这些主流的方法都主要局限在了两种常见的神经网络上，即 CNN 和 LSTM，并以此来学习表示原始文本的特征向量，然而随着原始文本中语句长度的逐渐变大，即富语境条件下，CNN 通过卷积核的短程滑动窗口难以再捕捉到语句中的长程关系依赖，继而抽取效果变差；LSTM 则受困于梯度消散造成的训练困难，时间长效率低。所以我们不得不重新思考，除了这两种神经网络外，是否可以有别的单语句编码器来获得更好的特征向量表示。

1.3 论文贡献

本篇论文中，作者对以前的基于神经网络的关系抽取方法进行了调研与统一的自主实现作为基线模型，同时提出了一种新型的单语句编码器（RE_NetVLAD）对原始文本中的句子进行向量表示，并在此基础上进行最终的关系类别预测。文

章的主要贡献有如下三个方面：

- 自主实现了数个常见的神经关系抽取模型，并在统一的超参数设置下，在一个被广泛使用的公开数据集上进行了评测和对比，为之后的工作提供了较为统一的标准基线模型集合。
- 不同于以往建立在 CNN 和 LSTM 基础上的神经关系抽取模型，论文提出了一种新型的单语句编码器（RE_NetVLAD），并在一个大规模公开数据集上取得了最好的单模型效果，同时在不同的设定下都可以在训练效率和抽取结果上给出稳定且有竞争力的表现。
- 实验证明，相比于 CNN 和 LSTM，RE_NetVLAD 对于语句长度的变化更加鲁棒，随着语句长度的增加，关系抽取的效果受到的影响较小。同时 RE_NetVLAD 对于自身的超参数设定也有很强的鲁棒性，在超参数很大的变化范围内，模型都能给出一致而稳定的抽取效果。
- 通过案例分析可以发现，RE_NetVLAD 模型内部的聚类操作，有着丰富的可解释性的语言学意义，论文针对这一现象进行了分析和讨论。

本篇论文的主要结构如下所示：

- **第一章 引言** 主要介绍了知识图谱的相关知识，由此引出关系抽取这一重要任务，并从两个方面简要回顾了以往的工作。最后介绍了本文的目标和贡献。
- **第二章 基于神经网络的关系抽取方法综述** 系统地介绍了基于神经网络方法的关系抽取系统，并详细介绍了几种常见的模型以及具体实现方法。
- **第三章 RE_NetVLAD：一种新型可学习池化的单语句编码器** 详细介绍了本文提出的新模型 RE_NetVLAD 以及具体实现方法。
- **第四章 实验结果与分析** 介绍了一个知名的大规模公开数据集，并在该数据集上，在统一的超参数设置下，对常见的神经关系抽取模型以及本文提出的新模型进行了统一的评测。之后对实验结果以及模型有效性和鲁棒性进行了定量分析。最后对模型的内部聚类操作的可解释性的语言学意义进行了案例分析和探讨。
- **第五章 文章结论与未来工作** 总结文章结论，并根据实验结论对未来工作进行了展望。

第2章 基于神经网络的关系抽取方法综述

近年来,深度学习^[17]已经成为机器学习领域中最具有发展前景的技术之一,被广泛应用于计算机视觉,语音识别,机器翻译,句法解析,情感分析等各种应用领域。神经关系抽取采用端到端的神经网络对整个关系抽取过程进行建模,其组成结构主要包括:单语句编码器,它捕获输入语句的语义并将其表示为语句的特征向量;关系抽取器,使用单个或多个单语句向量来生成目标实体对在所有关系类型上的概率密度分布。相比较于传统的借助人工特征的统计机器学习模型,神经网络模型的优势主要在如下两点:

- 神经网络采用完全端到端的学习和训练方式,直接在原始文本输入上进行训练,不需要借助人工设计的语义学特征,因而也相应地避免了受到特征提取不准确带来的错误叠加的问题。同时神经网络有着强大的表示学习能力,通过有监督的训练,可以自行学到输入数据的最有效的表示向量。由于其端到端的训练方式,表示学习与分类学习同时进行,可以大大提高表示学习的效果。
- 借助于线性变换和非线性激活函数的多层组合,神经网络相比于传统的统计机器学习方法有着更强的拟合能力。尤其是在自然语言处理任务上,文本和语言数据本身就有着极其复杂度非线性语义结构,而这远远超出了传统方法的拟合能力范围。得益于强大的拟合高维空间函数的能力,神经网络也因而可以相对较好地捕捉输入语句中复杂的语义关系,从而在关系预测时做出更好的判断。

神经关系抽取(Neural Relation Extraction, NRE)包括两个主要任务类型:单语句关系抽取和多语句关系抽取(或称为篇章级关系抽取)。在接下来的部分,我们从这两个方面分别对神经关系抽取系统进行模块化的详细介绍。

2.1 单语句关系抽取

单语句关系抽取旨在对一个句子中出现的目标实体对进行语义关系预测。也就是说,给定一个输入语句 x ,其中 x 由 m 个单词构成,即 $x = (w_1, w_2, \dots, w_m)$ 。语句对应的目标实体对为 e_1 和 e_2 。单语句关系抽取的目标在于通过一个神经网络获得目标实体对 (e_1, e_2) 在当前语句环境 x 下,拥有关系类型 $r(r \in \mathbb{R})$ 的条件

概率，即 $p(r|x, e_1, e_2)$ 。即：

$$p(r|x, e_1, e_2) = p(r|x, e_1, e_2, \theta), \quad (2-1)$$

其中 θ 是神经网络的所有可学习参数， r 是总的关系类型集合 $\mathbf{R}$ 中的一个。

一个基础的语句级别神经关系抽取由三个部分组成：(a) 输入编码器，它将输入的语句单词表示为向量；(b) 语句编码器，它通过对 (a) 中得到的向量序列计算获得语句最终的向量化表示；(c) 关系分类器，他计算在所有关系类型上的概率分布。

2.1.1 输入编码器

首先，系统将原始文本单词映射到连续的向量空间，从而得到原语句的输入表示 $\mathbf{w} = \{\mathbf{w}_1; \mathbf{w}_2; \dots; \mathbf{w}_m\}$ 。

词嵌入向量^[18] 学习了单词的一种低维向量化表示，它反应了单词之间的语义关联。每个单词 w_i 都被编码为词嵌入向量字典矩阵 $\mathbf{V} \in \mathbb{R}^{d^a \times |V|}$ 中的一个列向量，其中 V 表示词典的固定大小，其中 d^a 是词向量的维度。

位置嵌入向量旨在表示语句中每个单词与目标实体对的相对位置信息。分别根据与两个目标实体间的相对距离，每个单词 w_i 可以表示为对应的位置向量。例如，在句子 “*New York is a city of United States*” 中，单词 “city” 相对实体 *New York* 和 *United States* 的距离分别为 3 和 -2。

语法标签嵌入向量旨在表示目标单词在与语句中的语义学位置，如主语、谓语等。由于词向量是从大规模的语料上训练得到，因此它表示的信息可能并没有办法与具体句子的语境相匹配，所以有必要将每个单词与它所对应的句法位置结合起来。同词向量一样，每个单词 w_i 可以被编码为语法标签嵌入向量集合矩阵 $\mathbf{V}^p \in \mathbb{R}^{d^p \times |V^p|}$ 中的一个列向量，其中 d^p 是嵌入向量的维度， V^p 表示固定的句法标签字典的大小。

2.1.2 单语句编码器

接下来，单语句编码器将输入的向量序列编码成一个向量 $\mathbf{x}$ ，我们将介绍如下几个有代表性的单语句编码器：

卷积神经网络编码器^[19] 通过一个卷积神经网络 (CNN) 对输入的文本抽取局部特征并通过一个最大池化操作得到一个原始语句的固定大小的向量表示。

如图2.1所示，卷积操作被定义为一个向量序列和一个有着滑动窗口的卷积核矩阵 $\mathbf{W}$ 的矩阵乘法操作，之后再与偏置向量 $\mathbf{b}$ 相加。向量 $\mathbf{q}_i$ 被定义为第 i 个




图 2.1 带有最大池化层和非线性层的卷积神经网络（CNN）编码器。

滑动窗口内的数个输入向量的收尾拼接，则整个过程可以表示为：

$$[\mathbf{x}]_j = \max_i [f(\mathbf{W}\mathbf{q}_i + \mathbf{b})]_j, \quad (2-2)$$

其中函数 f 为一个非线性激活函数例如 Sigmoid 函数或双曲正切（tanh）函数。

更进一步，为了更好地获取两个实体间的结构化信息，^[13] 提出了基于分段化最大池化操作的卷积神经网络（Piecewise CNN, PCNN）。与传统的最大池化操作不同，它在两个实体将语句分成的三个片段上分别进行独立的最大池化操作，最后再将得到的三个向量拼接在一起成为最终的表示向量。

另一方面，为了提取更好的特征，^[16] 提出使用计算机视觉领域常用的残差网络成功将卷积神经网络的层数变多，并取得了一定的效果提升。残差网络的主要结构如图2.2所示。通过特有的跳跃式连接（skip connection）可以使得在网络变深的时候，梯度可以得到更有效的回传。

循环神经网络编码器^[21] 旨在利用 RNN 的可以处理有时序数据的特点，得到输入语句的向量化表示。如图2.3所示，每个单词的表示向量按照顺序被依次输入进网络中。对于第 i 步，网络的输入为词的向量表示 $\mathbf{w}_i$ 和上一步 $i-1$ 的输




图 2.2 残差网络（ResNet）结构^[20]中的跳跃式连接（skip connection）。可以使得网络在变深的时候，梯度可以更好地进行回传，从而加速网络的训练，并提升训练效果。




图 2.3 带有最大池化层的双向循环神经网络（Bi-RNN）结构。

出 $\mathbf{h}_{i-1}$ ，所以我们有

$$\mathbf{h}_i = f(\mathbf{w}_i, \mathbf{h}_{i-1}), \quad (2-3)$$

其中 f 表示 RNN 单元结构内部的变换函数，可以是 LSTM^[22] 或者 GRU^[23]。当是 LSTM 单元时，具体变化如下：

$$\mathbf{i}_t = \sigma(\mathbf{W}^{(i)}\mathbf{w}_t + \mathbf{U}^i\mathbf{h}_{t-1} + \mathbf{b}^{(i)}), \quad (2-4)$$

$$\mathbf{f}_t = \sigma(\mathbf{W}^{(f)}\mathbf{w}_t + \mathbf{U}^f\mathbf{h}_{t-1} + \mathbf{b}^{(f)}), \quad (2-5)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}^{(o)}\mathbf{w}_t + \mathbf{U}^o\hat{\mathbf{h}}_t + \mathbf{b}^{(o)}), \quad (2-6)$$

$$\mathbf{u}_t = \sigma(\mathbf{W}^{(u)}\mathbf{w}_t + \mathbf{U}^u\mathbf{h}_{t-1} + \mathbf{b}^{(u)}), \quad (2-7)$$

$$\mathbf{c}_t = \mathbf{i}_t \odot \mathbf{u}_t + \mathbf{f}_t \odot \mathbf{c}_{t-1}, \quad (2-8)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \sigma(\mathbf{c}_t). \quad (2-9)$$

采用双向 RNN 网络可以更加全面地利用全局的语义信息，因此可以将前向 RNN 和后向 RNN 的最终输出状态 $\mathbf{h}_m^f, \mathbf{h}_m^b$ 首尾拼接起来作为最终的语句表示。除此之外，双向 RNN 每一步的中间状态 $\mathbf{h}_i$ 对应于结合了从前向后和从后向前的两方面信息，所以也可以采用一个最大池化层将这些局部特征向量聚合成一个全局特征作为整个句子的向量化表示。最大池化层可以表示成：

$$[\mathbf{x}]_j = \max_i [\mathbf{h}_i]_j \quad (2-10)$$

除了最大池化操作，单词级别的注意力机制也可以用来聚合这些局部特征向量。它使用注意力模型^[10]去学习每一步状态在聚合时对应的权重值。矩阵 $\mathbf{H} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_m]$ 为 RNN 所有输出向量构成的矩阵，则整个句子的特征向量 $\mathbf{x}$ 可以表示为每一步输出状态的加权求和：

$$\alpha = \text{softmax}(\mathbf{s}^T \tanh(\mathbf{H})) \quad (2-11)$$

$$\mathbf{x} = \mathbf{H}\alpha^T \quad (2-12)$$

其中 $\mathbf{s}$ 是一个可学习的查询向量， $\mathbf{s}^T$ 表示它的转置。

除此之外，^[15]提出了一个可以同时考虑词序信息和语法依存树（dependency tree）子结构信息的模型，它在原来输出的基础上堆叠了又一层基于依存树路径的双向 RNN，如图2.4所示，它关注目标实体对在依存树上的最短路径，^[24]中的实验也显示依存树信息对关系分类有很大作用。

递归神经网络旨在从句法分析树结构中抽取特征向量，因为句法信息对于抽取关系十分重要。总体来说，这些编码器将句法树作为合成策略以及递归神经网络将每个词嵌入向量组合起来的方向。

^[12]提出了一种递归的矩阵-向量表示模型（recursive matrix-vector model, MV-RNN），模型中每个单词有向量和矩阵两种表示，向量用来表示单词本身的含义，矩阵则用来表示该单词会如何修改与它同在一个语法树分支的单词的含义。假




图 2.4 基于句法依存树的 LSTM 网络结构。其中带有箭头的实线表示依存树上的最短路径。带有箭头的虚线表示向量的输出方向。

如在句法树中，我们有两个子结点 l, r 和他们的父结点 p ，则他们的组合就可以表示为：

$$\mathbf{p} = f_1(l, r) = g\left(\mathbf{W}_1 \begin{bmatrix} \mathbf{B}\mathbf{a} \\ \mathbf{A}\mathbf{b} \end{bmatrix}\right) \quad (2-13)$$

$$\mathbf{P} = f_2(l, r) = \mathbf{W}_2 \begin{bmatrix} \mathbf{A} \\ \mathbf{B} \end{bmatrix} \quad (2-14)$$

其中 $\mathbf{a}, \mathbf{b}, \mathbf{p}$ 是每个节点的嵌入式向量表示， $\mathbf{A}, \mathbf{B}, \mathbf{P}$ 是矩阵表示， $\mathbf{W}_1$ 是用来将词向量变换到新的语义空间的变换矩阵， g 为激活函数。 $\mathbf{W}_2$ 为将两个矩阵结合为一个新的维度相同的矩阵 $\mathbf{P}$ 的变换矩阵。整个过程如图2.5所示。MV-RNN 选择在两个目标实体间的树结构上最高的结点向量作为整句话的表示。

事实上，这里的递归神经元结构也可以被替换为 LSTM 或者 GRU。^[25] 提出了两种树结构 LSTM 去捕获句法树中的信息。其中一个常用的 Child-Sum Tree-LSTM 的结构如下所示， $C(t)$ 是结点 t 所对应的子结点集合：

$$\hat{\mathbf{h}}_t = \sum_{k \in C(t)} \mathbf{h}_k, \quad (2-15)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}^{(i)} \mathbf{w}_t + \mathbf{U}^i \hat{\mathbf{h}}_t + \mathbf{b}^{(i)}), \quad (2-16)$$

$$\mathbf{f}_{tk} = \sigma(\mathbf{W}^{(f)} \mathbf{w}_t + \mathbf{U}^f \mathbf{h}_k + \mathbf{b}^{(f)}) \quad (k \in C(t)), \quad (2-17)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}^{(o)} \mathbf{w}_t + \mathbf{U}^o \hat{\mathbf{h}}_t + \mathbf{b}^{(o)}), \quad (2-18)$$




图 2.5 矩阵-向量递归神经网络模型结构。每个词都有向量和矩阵两种表示方法。带有箭头的实线表示语法依存树上的路径。

$$\mathbf{u}_t = \tanh(\mathbf{W}^{(u)} \mathbf{w}_t + \mathbf{U}^u \hat{\mathbf{h}}_t + \mathbf{b}^{(u)}), \quad (2-19)$$

$$\mathbf{c}_t = \mathbf{i}_t \odot \mathbf{u}_t + \sum_{k \in C(t)} \mathbf{f}_{tk} \odot \mathbf{c}_{t-1}, \quad (2-20)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t). \quad (2-21)$$

2.1.3 关系分类器

当我们得到了输入句子的向量化表示 $\mathbf{x}$ 后，关系分类器可以通过一个 softmax 层计算条件概率 $p(r|x, e_1, e_2)$:

$$p(r|x, e_1, e_2) = \text{softmax}(\mathbf{M}\mathbf{x} + \mathbf{b}), \quad (2-22)$$

其中 $\mathbf{M}$ 表示关系矩阵， $\mathbf{b}$ 是偏置向量。

2.2 多语句关系抽取（篇章级关系抽取）

虽然现有的神经模型在提取新的关系事实方面取得了巨大的成功，但它总是缺乏训练数据。为了解决这个问题，研究人员提出了远程监督的假设，通过链接现有知识图谱和纯文本自动生成训练数据。远程监督的直觉假设是，所有含有两个实体的句子都将表达它们在知识图谱中的关系。例如，(*New York*, city_of, *United States*) 是知识图谱中的关系事实。远程监督假设将把包含这两个实体的所有句子视为关系 city_of 的有效实例。它提供了利用多语句（篇章级）而不是单语句信息的自然方式来决定两个实体之间是否存在关系。

因此，多语句关系抽取旨在使用所有涉及的句子来预测实体对之间的语义关系。给定由 n 个输入句子组成的集合 $S = (x_1, x_2, \dots, x_n)$ 及其相应的目标实体对 e_1 和 e_2 ，目标是通过一个神经网络获得关系 $r(r \in \mathbb{R})$ 的条件概率 $p(r|S, e_1, e_2)$ ，可以形式化为：

$$p(r|S, e_1, e_2) = p(r|S, e_1, e_2, \theta). \quad (2-23)$$

多语句关系抽取的主要由四部分组成：(a) 类似于单语句级关系抽取的输入编码器，(b) 类似于单语句级关系抽取的单语句编码器，(c) 多语句编码器，用于计算得到一个表示所有相关语句的向量，以及 (d) 类似于单语句级关系抽取的关系分类器，其将多语句表示向量作为输入而不是单语句表示向量。接下来，我们将详细介绍多语句编码器和关系分类器。

2.2.1 多语句编码器

多语句编码器将所有单语句向量编码成一个向量 $\mathbf{S}$ 。以下介绍多种类型：

随机编码器. 假设每个句子都能表达目标实体对间的关系，所以随机选取一个句子向量去表示整个语句集合：

$$\mathbf{S} = \mathbf{x}_i \ (i = 1, 2, \dots, n), \quad (2-24)$$

其中 $\mathbf{x}_i$ 表示第 i 个句子对应的向量表示， i 为一个随机数值。

最大编码器. 事实上，正如前文所说，并非所有包含目标实体对的句子都能表达它们之间的关系。比如，句子 “New York City is the premier gateway for legal immigration to the United States” 并没有表达关系 `city_of`。所以^[13] 假设每个集合中至少有一个句子可以表达目标实体对的关系，然后以此为依据，选择具有最高概率值的句子作为语句集合的向量代表：

$$\mathbf{S} = \mathbf{x}_i \ (i = \operatorname{argmax}_i p(r|x_i, e_1, e_2)). \quad (2-25)$$

平均编码器. 以上两个编码器都只用了一个句子去代表整个集合，这样会忽略掉很多句子中的有用信息。为了去发掘所有语句中的信息，^[7] 认为集合的表示 $\mathbf{S}$ 应该取决于所有单语句的向量表示 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 。每个语句表示 $\mathbf{x}_i$ 可以提供在当前语句语境下实体对的关系信息。平均编码器假设所有的句子对于集合的表示贡献是相同的，也就是说最终的集合表示 $\mathbf{S}$ 是所有句子向量的平均：

$$\mathbf{S} = \sum_i \frac{1}{n} \mathbf{x}_i. \quad (2-26)$$

基于注意力机制的编码器。 由于远程监督带来的不可避免的错误标注的问题，为了解决这一问题，^[7] 进一步提出了一种选择性注意力机制来降低这些噪音数据的负面影响，即最终的集合表示定义为集合内单语句向量的加权平均：

$$\mathbf{S} = \sum_i \alpha_i \mathbf{x}_i, \quad (2-27)$$

其中 α_i 被定义为：

$$\alpha_i = \frac{\exp(\mathbf{x}_i \mathbf{A} \mathbf{r})}{\sum_j \exp(\mathbf{x}_j \mathbf{A} \mathbf{r})}, \quad (2-28)$$

其中 $\mathbf{A}$ 是一个对角矩阵， $\mathbf{r}$ 是关系类型 r 的表示向量。

2.2.1.1 关系分类器

类似于单语句关系抽取，当得到多语句集合的表示向量 $\mathbf{S}$ 后，关系分类器可以通过一个 softmax 层计算条件概率 $p(r|S, e_1, e_2)$ ：

$$p(r|S, e_1, e_2) = \text{softmax}(\mathbf{M}' \mathbf{S} + \mathbf{b}'), \quad (2-29)$$

其中 $\mathbf{M}'$ 表示关系矩阵， $\mathbf{b}'$ 表示偏置向量。

第 3 章 RE_NetVLAD：一种新型可学习池化的单语句编码器

3.1 基于传统特征的计算机视觉中的 VLAD 方法

在深度学习之前的计算机视觉研究领域，基于许多人工设计的局部特征算子例如 SIFT^[26] 等，可以得到成千上万的图像局部特征向量，但是在图像检索和图像分类等具体任务中，需要一个有效的整体特征向量来聚合化地表示所有的成千上万的局部特征向量，为了解决这一问题，研究人员们相继提出了词袋模型（Bag of Features）^[27]、Fisher 核（Fisher Kernel）^[28] 等方法，其中由^[29] 提出的 VLAD（Vector of Locally Aggregated Descriptors, 局部特征聚合描述向量）方法得到了广泛的应用。与传统的词袋模型方法不同，VLAD 没有直接计算目标图片中所包含的每个视觉词汇向量的数量，而是对于每个聚类中心计算了其聚类区域内局部特征向量和它的残差（residual）的和。

形式化的来讲，即给定 N 个 D 维的局部特征向量 $\mathbf{x}_i$ 作为输入，以及 K 个聚类中心 $\mathbf{c}_k$ 作为 VLAD 的模型参数，这里的聚类中心是通过对所有局部特征向量进行 k-means 得到的。则最终 VLAD 输出的整体表示向量 V 维度为 $D \times K$ 维。为了方便表示，这里将 V 写成一个维度为 $D \times K$ 的矩阵形式，则矩阵 V 的 (j, k) 位置的元素可以通过如下计算得到：

$$V(j, k) = \sum_{i=1}^N a_k(\mathbf{x}_i)(x_i(j) - c_k(j)), \quad (3-1)$$

其中 $x_i(j)$ 和 $c_k(j)$ 分别是第 i 个局部特征向量 $\mathbf{x}_i$ 的第 j 维度和第 k 个聚类中心的第 j 维度。 $a_k(\mathbf{x}_i)$ 表示局部特征向量 $\mathbf{x}_i$ 是否归属于第 k 个聚类中心的聚类区域，即当聚类中心 $\mathbf{c}_k$ 对于局部特征向量 $\mathbf{x}_i$ 是最近的聚类中心时， $a_k(\mathbf{x}_i) = 1$ ，否则 $a_k(\mathbf{x}_i) = 0$ 。整体来看，矩阵 V 的第 k 个 D 维的列向量记录着归属于聚类中心 $\mathbf{c}_k$ 的所有局部特征向量 $\mathbf{x}_k$ 与聚类中心 $\mathbf{c}_k$ 的残差 $(\mathbf{x}_k - \mathbf{c}_k)$ 。在得到矩阵 V 之后，先对矩阵的列向量进行 L2 归一化^[30]，然后再将矩阵转化成向量，再对整体进行 L2 归一化^[29]。

相比于简单直接地对所有局部特征向量最大池化和平均池化从而得到聚合的整体向量，VLAD 方法可以更好地捕捉到所有局部特征向量在向量空间的分布形式，并且通过残差的方式尽可能多地保留了局部特征的分布信息，得到的

聚类中心也有着丰富的可解释的物理含义。三种池化方法的区别可以从图3.1中的对比看出。




图 3.1 最大池化和平均池化方法与 VLAD 的对比。a, b, c 依次为最大池化，平均池化和 VLAD。图中不同颜色的点代表不同子区域的局部特征向量，五角星在 a、b 中代表池化后的最终表示向量，在 c 中代表聚类中心。

3.2 基于深度学习的计算机视觉中的 NetVLAD 方法

在基于传统计算机视觉特征的时代，VLAD 方法在各种任务上成功取得了效果和效率的双重提升。但是随着深度学习时代的到来，有监督学习下神经网络提取的特征在各种任务下都被证明远优于人工设计的特征，而 VLAD 方法中的 k-means 聚类操作并不可微分，也就和神经网络训练的反向传播算法并不相容，所以无法与神经网络相结合。所以为了充分利用 VLAD 的聚合表示方法，^[31]提出了一种基于 VLAD 的新型可学习池化方法，将原来方法中的不可微分操作巧妙的变为了神经网络中的可微分操作，从而可以使用基于反向传播算法的优化器进行训练，成功使得 VLAD 兼容了神经网络框架，并在包括图像检索、视频理解^[32]等一系列任务上取得了成功。

原始 VLAD 方法中，不可微分的不连续操作来自于计算 $a_k(\mathbf{x}_i)$ ，即判断局部特征向量 $\mathbf{x}_i$ 是否属于聚类中心 $\mathbf{c}_k$ 。为了使这一操作变得可微，NetVLAD 将 k-means 中的分立式的聚类分配（hard assignment）变成了连续式的聚类分配（soft assignment），即每个局部特征向量不再只归属于一个确定的聚类中心，而是以一个归一化的概率分布归属于所有的聚类中心。形式化的来说，就是原表达式中的 $a_k(\mathbf{x}_i)$ 通过如下计算得出：

$$a_k(\mathbf{x}_i) = \frac{e^{-\alpha \|\mathbf{x}_i - \mathbf{c}_k\|^2}}{\sum_{k'} e^{\alpha \|\mathbf{x}_i - \mathbf{c}_{k'}\|^2}} \quad (3-2)$$

即根据 $\mathbf{x}_i$ 到聚类中心 $\mathbf{c}_i$ 的距离来决定分配的权值，其中 α 是一个决定距离影响的超参数。当 $\alpha \rightarrow \infty$ 时，NetVLAD 会退化成 VLAD，即对于最近的聚类中心 $a_k(\mathbf{x}_i)$ 等于 1，其他情况等于 0。将上述式子进行展开，可以将 $e^{-\alpha \|\mathbf{x}_i\|^2}$ 项消掉，从而可以化简为如下形式：

$$a_k(\mathbf{x}_i) = \frac{e^{\mathbf{w}_k^T \mathbf{x}_i + b_k}}{\sum_{k'} e^{\mathbf{w}_k^T \mathbf{x}_i + b_k}} \quad (3-3)$$

其中 $\mathbf{w}_k = 2\alpha \mathbf{c}_k$ ， $b_k = -\alpha \|\mathbf{c}_k\|^2$ 。则 NetVLAD 中的矩阵 V 可以表示为：

$$V(j, k) = \sum_{i=1}^N \frac{e^{\mathbf{w}_k^T \mathbf{x}_i + b_k}}{\sum_{k'} e^{\mathbf{w}_k^T \mathbf{x}_i + b_k}} (x_i(j) - c_k(j)) \quad (3-4)$$

其中 $\mathbf{w}_k$ ， b_k 和 $\mathbf{c}_k$ 是模型中对于第 k 个聚类中心的可学习参数。与原始的 VLAD 相似，NetVLAD 以加权平均的方式反映了每个局部特征与聚类中心的残差 $(\mathbf{x}_i - \mathbf{c}_k)$ 。不同的是，NetVLAD 中的有三组相互独立的参数 $\mathbf{w}_k$ ， b_k 和 $\mathbf{c}_k$ ，而原始 VLAD 中只有一组 $\mathbf{c}_k$ ，参数量的变多也使得模型的表达能力更强，可以应对更复杂的情况，如图 3.2。




图 3.2 相比于原始 VLAD，有监督学习下的 NetVLAD 拥有更强的表达能力，可以处理更复杂的情况^[31]。例如上图中，红点和绿点都是局部特征向量，但属于两个不同类别的训练样例，但都归属在同一个聚类区域（图中的多边形框），聚类中心为 $\mathbf{c}_k$ 。两个训练样例的最终表示向量的相似度由两者残差向量的内积所决定。在原始 VLAD 中，聚类中心即（近似）为该聚类区域的中心 $\mathbf{c}_k^{VLAD}$ （ $\times$ ）。但是在有监督学习的 NetVLAD 中，可以得知两个训练样例并不属于同一类别，就有可能学习到一个更好的聚类中心 $\mathbf{c}_k^{NetVLAD}$ （ $\star$ ），使得两者的残差向量的内积更小。

3.3 可学习池化的单语句编码器 RE_NetVLAD

不难发现，其实现有神经关系抽取框架中的单语句编码器的本质目的和 VLAD 方法相同，即两者都希望通过计算得出一个单向量作为向量序列的整体表示，唯一的区别在于 VLAD 面对的向量序列通常为图像的局部特征向量，而神经关系抽取中的为单个单词的嵌入式表示。受此启发，我们尝试将 NetVLAD 作为单语句编码器加入关系抽取框架，即面向关系抽取的 NetVLAD (NetVLAD for Relation Extraction, RE_NetVLAD)。

沿用第二章中的符号表示，单语句编码器的输入为由语句中单词的嵌入式向量构成的向量序列 $\mathbf{w} = \{\mathbf{w}_1; \mathbf{w}_2; \dots; \mathbf{w}_m\}$ ，输出为单语句的向量化表示 $\mathbf{x}$ ，假设总共有 K 个聚类中心。则 RE_NetVLAD 中的矩阵 V 可通过如下计算得到：

$$V(j, k) = \sum_{i=1}^m \frac{e^{\mathbf{w}_k^T \mathbf{w}_i + b_k}}{\sum_{k'} e^{\mathbf{w}_k^T \mathbf{w}_i + b_k}} (x_i(j) - c_k(j)) \quad (3-5)$$

其中 $x_i(j)$ 和 $c_k(j)$ 分别是第 i 个单词的嵌入式向量表示 $\mathbf{x}_i$ 的第 j 维度和第 k 个聚类中心的第 j 维度。在具体实现中，与偏置项的求和操作被替换成了效果更好的批归一化操作 (Batch Normalization)^[33]。在得到矩阵 V 后，再对它的每列向量进行独立的 L2 归一化得到新的矩阵 V' ，使用 $\mathbf{v}_k$ 代表矩阵的第 k 个列向量，即：

$$\mathbf{v}_k = V(:, k) \quad (3-6)$$

$$\mathbf{v}_k := \frac{\mathbf{v}_k}{\|\mathbf{v}_k\|_2} \quad (3-7)$$

$$V' = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_K] \quad (3-8)$$

之后将矩阵 V' 转化成向量，并进行 L2 归一化，得到的就是最终的单语句表示向量 $\mathbf{x}$ ：

$$\mathbf{x} = [V'(:, 1)^T, V'(:, 2)^T, \dots, V'(:, K)^T] \quad (3-9)$$

$$\mathbf{x} := \frac{\mathbf{x}}{\|\mathbf{x}\|_2} \quad (3-10)$$

如此一来，便可将单语句向量 $\mathbf{x}$ 输入到单语句关系分类器，或者收集多个单语句向量输入到多语句关系分类器中，得到目标实体对最终的关系预测结果，即 RE_NetVLAD 作为单语句编码器可以很好地嵌入到第二章中所介绍的现有的神经关系抽取框架中。

图3.3给出了一个 RE_NetVLAD 的具体案例，其中输入总共有 3 个单词嵌入向量，2 个聚类中心，即 $m = 3, K = 2$ 。




图 3.3 聚类中心数目为 2 的 RE_NetVLAD 网络结构。

第 4 章 实验结果与分析

4.1 数据集与评测指标

在关系抽取任务上，由^[2]提出的数据集^①得到了众多研究者的广泛使用^[3,7,13]。这个数据集是由远程监督方法自动生成，链接了纽约时报语料库（New York Times Corpus, NYT）和 Freebase 知识图谱中的实体对与关系类型，为了避免重复，训练集中包含的是 2005-2006 年的语料库，测试集为 2007 年的语料库，且测试集中的三元组没有在训练集中出现过。包括特殊关系类型“NA（没有关系）”在内，数据集总共包含 53 种关系类型。训练集总共包含了 522,611 个单语句，281,270 个实体对和 18,252 个关系事实（三元组）。测试集总共包含了 172,448 个单语句，96,678 个实体对和 1,950 个关系事实（三元组）。

遵循^[1]中的设定，我们在除了 NA 关系类型以外的有效关系类型上测试模型效果。测试的指标除了之前研究者常用的准确率-召回率曲线（Precision-Recall Curve）和前 N 个数据的准确率（Precision@N, P@N），我们还新引入了整体平均准确率（Global Average Precision, GAP）：

$$GAP = \sum_i^N p(i) \Delta r(i) \quad (4-1)$$

其中 $p(i)$ 和 $r(i)$ 分别为前 i 个数据的准确率和召回率。

4.2 RE_NetVLAD 与基线模型的效果对比

正如第一章引言中所介绍，我们将神经关系抽取领域内前人提出的几种被广泛使用的方法都进行了集中的自主实现，并在绝大多数模型上都获得了和原论文中结果的误差在可解释范围内的效果。这些方法都在第二章神经关系抽取系统综述内有介绍，其中两种基于语法依存树的方法由于考虑了人工特征，故不在我们的比较范围内。

进行比较的基线模型的单语句编码器主要分为如下两类：

- 基于卷积神经网络（CNN）的单语句编码器：

① <http://iesl.cs.umass.edu/riedel/ecml/>

- **CNN+max**: 使用最大池化层的 CNN 网络^[19]。
- **PCNN**: 使用分段最大池化 CNN 网络^[13]。
- **CNN+word_att**: 使用单词级别的注意力机制的 CNN 网络^[34]。
- **ResCNN+max**: 使用最大池化的残差卷积网络^[16]。这里沿用原论文实验中最好的效果对应模型超参数，即有 4 个 residual block，共 9 个卷积层。
- 基于双向长短时记忆模型（Bi-LSTM）的单语句编码器：
 - **Bi-LSTM**: 使用双向 LSTM 的最终输出向量的拼接。
 - **Bi-LSTM+max**: 沿着句子长度维度进行最大池化的双向 LSTM。
 - **Bi-LSTM+word_att**: 使用单词级别的注意力机制的双向 LSTM^[34]。

包括 RE_NetVLAD 在内的所有单语句编码器都在平均编码器（AVG）和基于注意力机制的编码器^[7]（ATT）两种多语句编码器下进行了训练和测试。CNN 和 RE_NetVLAD 的超参数设定除学习率外基本遵循以前的论文，LSTM 的超参数设定通过多重验证得出最优配置，两者如表4.1所示：

表 4.1 不同模型的超参数设置。

模型类型	CNN	RE_NetVLAD	Bi-LSTM
滑动窗口大小 l	3	NA	NA
单语句表示向量维度 d^c	230	230	320
词向量维度 d^a	50	50	50
位置嵌入向量维度 d^b	5	5	5
批训练数据数量 B	160	160	160
学习率 λ	0.1	0.1	0.5
dropout 概率 p	0.5	0.5	0.5

除此之外，激活函数统一使用的 relu，优化器都使用的 SGD。RE_NetVLAD 在这里设定的聚类中心数目 K 为 100，为了使对比更加公平，在得到 60×100 维的输出向量后，会使用一个全连接层对其进行降维，从而得到维度为 230 的最终单语句表示向量。词向量采用^[7]中所使用的通过在 NYT 语料上用 word2vec^①训练得到的词向量。另外 Bi-LSTM 中采用的位置嵌入向量表示与其他模型不同，如果该单词是目标实体，则位置向量为单位向量（每个维度的值都是 1），否则为零向量，且该向量固定不变，不参加训练过程；其他模型所采用的位置嵌入向

① <http://code.google.com/p/word2vec>

量表示中，采用随机初始化，且参与训练过程。Bi-LSTM 的 dropout 位置在单语句编码器的输入处，其他模型在关系分类器输入处。训练的轮数按照^[7]中所设定的定为 24 轮（epoch），此时训练时损失函数的表现和测试集上附近轮数的效果都已经趋于稳定，可验证得这一超参数的设置是合理的。

RE_NetVLAD 与上述基线模型在测试集上的效果如表4.2所示。

表 4.2 RE_NetVLAD 与基线模型的效果比较。

多语句编码器	AVG					ATT				
P@N(%)	100	200	300	Mean	GAP	100	200	300	Mean	GAP
CNN+max	81.0	71.0	67.0	73.0	35.3	78.0	67.5	66.7	70.7	36.1
PCNN	82.0	76.0	67.3	75.1	36.5	76.0	71.5	70.0	72.5	38.2
CNN+word_att	66.0	64.5	64.7	65.1	33.2	71.0	67.0	64.0	67.3	31.2
ResCNN+max	68.0	65.5	63.0	65.5	34.0	74.0	71.0	72.3	72.4	35.2
Bi-LSTM	68.0	69.0	66.7	67.9	35.2	74.0	70.5	66.3	70.3	36.2
Bi-LSTM+max	78.0	71.0	67.7	72.2	37.4	77.0	77.0	73.7	75.9	39.8
Bi-LSTM+word_att	80.0	73.0	68.7	73.9	37.3	76.0	73.0	69.7	72.9	39.5
RE_NetVLAD	69.0	70.0	66.3	68.4	37.2	82.0	76.0	72.3	76.8	40.0




图 4.1 基于 CNN+AVG 的模型族在测试集上的准确率-召回率曲线（最好在有颜色的环境下观看）。




图 4.2 基于 CNN+ATT 的模型族在测试集上的准确率-召回率曲线（最好在有颜色的环境下观看）。




图 4.3 基于 Bi-LSTM+AVG 的模型族在测试集上的准确率-召回率曲线（最好在有颜色的环境下观看）。




图 4.4 基于 Bi-LSTM+ATT 的模型族在测试集上的准确率-召回率曲线（最好在有颜色的环境下观看）。

同时为了更直观也更全面的展现模型在全测试集上的效果并进行对比,这里分成了四组来绘制准确率-召回率曲线,分别为基于 CNN+AVG 的模型族(图4.1),基于 CNN+ATT 的模型族(图4.2),基于 Bi-LSTM+AVG 的模型族(图4.3),基于 Bi-LSTM+ATT 的模型族(图4.4)。其中每个都添加了使用相同多语句编码器的 RE_NetVLAD 来进行对比。

首先,对我们新提出的 RE_NetVLAD 模型进行评估:

- 从表4.2中可以看到, RE_NetVLAD 在 ATT 的设定下可以取得所有模型中最好的效果, GAP 可以达到 40.0, 并在 P@N 指标上也明显优于其他模型; RE_NetVLAD 在 AVG 的设定下与同类模型相比,虽然不是最好的效果,但其 37.2 的 GAP 距离最高的 37.4 十分接近。
- 从图4.2和4.4中可以看到,在 ATT 设定下,与 CNN 相比, RE_NetVLAD 明显优于所有基于 CNN 的单语句编码器,在低召回率时就能取得很高的准确率,且准确率随着召回率的提升下降相比其他 CNN 模型更加缓慢;与 Bi-LSTM 相比,由于 LSTM 的效果已经十分好,所以 RE_NetVLAD 的优势并不是特别明显,模型间效果较为相似,彼此差距都较小。
- 从图4.1和4.3中可以看到,在 AVG 设定下,与 CNN 相比, RE_NetVLAD 的优势已经不如 ATT 时那么明显,甚至在低召回率的时候,准确率还会

低于其他模型，但是随着召回率的提高，RE_NetVLAD 的准确率维持着十分缓慢的下降，而其他模型则下降的较快，所以在召回率大于 0.15 后，RE_NetVLAD 的准确率就成为了最高；与 Bi-LSTM 相比，同 ATT 的设定，RE_NetVLAD 与其他 Bi-LSTM 模型都优于直接使用 LSTM 输出的 BiLSTM+AVG，与使用最大池化的 max 和单词级别注意力机制的 word_att 差距十分微小，仅在最开始召回率低于 0.1 的时候，准确率低于这两者，大于 0.1 之后，三者间的曲线也基本相互重合，并在波动中互有高低。

- 除了图表中的模型效果信息，我们也考虑对模型的训练效率进行比较。所有模型训练都在一块显存 8GB 的 NVIDIA GeForce GTX 1070 显卡环境下进行，RE_NetVLAD 的训练速度跟 CNN 模型基本相近，约为 1h，但是 Bi-LSTM 模型时间较长，约为 3h。从效率的角度看，在相同的训练时间下，RE_NetVLAD 可以取得远优于 CNN 的效果；在训练时间远小于 Bi-LSTM 的情况下，可以取得几乎相同甚至在 ATT 设定下更好的极为有竞争力的模型效果。

其次，对于基准线模型进行比较和观察：

- 对于多语句编码器来说，基于注意力机制的编码器（ATT）效果明显优于平均编码器（AVG）。通过对表格4.2中同一单语句编码器在 AVG 和 ATT 两种设定下效果的对比，可以看出 ATT 对于抽取效果显著而一致的提升，进一步验证了^[7]中的结论。在之后的实验中，对于同一模型，我们也选取 ATT 设定来做为其代表。
- 对于单语句编码器来说，得益于特有的对于序列化数据处理的优势，基于 Bi-LSTM 的模型整体上明显优于基于 CNN 的模型。
- CNN 模型中最有竞争力的效果来自于 PCNN，由于对原始语句进行了分段最大池化处理，相比于原始 CNN 保留了更多序列化的信息；相比于结构最简单的 CNN+max，另外两个分别使用了单词级别注意力机制和残差网络结构的模型，并没有取得任何效果的提升，甚至还有了不同程度的下降。其中 ResCNN 的模型效果基本符合^[16]中汇报的结果，甚至 P@N 指标上还有一些提升，但是原文中基线模型的效果与我们相比有些略低。
- Bi-LSTM 模型族内整体效果较为一致，无论采用基于单词级别注意力机制的池化还是最大池化，都能取得相比于直接使用最终输出向量的模型的明显的效果提升。但是需要注意的是，Bi-LSTM 的单词位置嵌入向量的输入和训练过程中 dropout 的位置都与 RE_NetVLAD 和 CNN 模型不同，这也




图 4.5 训练集中平均单语句长度的概率密度分布函数。横坐标为句子长度，纵坐标为长度在此区间内的句子数占总数的百分比。




图 4.6 测试集中平均单语句长度的概率密度分布函数。图例同左。

使得对模型的横向对比出现了一些困难。

4.3 模型的鲁棒性验证

为了进一步探讨我们提出的新模型 RE_NetVLAD 的稳定性和鲁棒性，从单语句长度和聚类中心数目两个方面进行了研究：

4.3.1 单语句长度

单语句长度是影响关系抽取模型效果的一个重要因素。随着语句长度的增加，语意也会变得更加复杂，处理序列化的信息也相应变得更难，这也就是所谓的富语境（rich context）情况。总的来讲，富语境还包括句子数目的增多、跨语句甚至段落的关系推理等，但在这里，我们先仅考虑语句长度的增加这一最简单，最基本，但同样难以处理的情况。

图4.5和图4.6分别计算了训练集和测试集中平均单语句长度的概率密度分布函数，图4.7和图4.8分别统计了训练集和测试集中平均单语句长度的具体数目分布。需要说明的是，因为我们的关系抽取系统是面向实体对而非单个语句的，所以这里的平均语句长度指的是同一个实体对所对应的多个语句的平均长度。

通过观察可以发现，训练集和测试集的分布几乎相同，两者都在语句长度上存在着不平均的现象，即绝大多数语句长度分布在 30 到 50 之间，这也比较符合现实中的自然语言分布。为了比较不同模型的效果随着语句长度变化而产生的变化，我们按照最大平均语句长度的阈值对原始测试集进行了筛选，只保留平均




图 4.7 训练集中平均单语句长度的数目分布。纵坐标为句子长度，横坐标为长度小于等于纵坐标的句子数目。




图 4.8 训练集中平均单语句长度的数目分布。图例同左。

语句长度在阈值以下的测试实体对，然后不断地提高阈值直到最大长度，由此绘制出模型的效果随着平均语句长度的分布变化而产生的变化。图4.9和4.10分别展示了 CNN+ATT 和 Bi-LSTM+ATT 模型族在测试集上的 GAP 指标随着最大平均语句长度阈值的变化而产生的变化：




图 4.9 基于 CNN+ATT 的模型族在测试集上的 GAP 指标与最大平均语句长度阈值的关系（最好在有颜色的环境下观看）。横坐标为最大平均语句长度的阈值，纵坐标为 GAP。




图 4.10 基于 Bi-LSTM+ATT 的模型族在测试集上的 GAP 指标与最大平均语句长度阈值的关系（最好在有颜色的环境下观看）。图例同上。

通过观察可以看出：

- 所有模型都呈现出，随着包含长语句的测试样例加入测试集合，模型效果不断下降的整体趋势，体现出长语句对于模型效果的负面影响，以及现有的模型在长语句的处理上仍有一定的提高空间。
- 与其他模型相比，语句长度增加对 RE_NetVLAD 的负面影响是最小的，1.9 个百分点。CNN 和 Bi-LSTM 模型中最大的波动都已经大于 4 个百分点，最小的波动分别为 PCNN 和 Bi-LSTM+word_att，对应 1.9 个百分点和 2.3 个百分点。由此可以看出 RE_NetVLAD 相比于现有模型，借助于特殊的可学习池化方法，可以尽可能多的保留局部序列信息，从而对于语句长度更加鲁棒。
- 在基于 CNN+ATT 的模型中，随着句子长度增加，模型效果波动都较大，CNN+max 和 CNN+word_att 的下降值都达到了 4 个百分点。PCNN 的变动较小，这个性质仍与其分段最大池化操作有关：对原语句的分段化处理相当于在一定程度上减少了所要处理的语句长度，从而当整体长度发生变化时，对分段的影响就会相对小一些，这与 RE_NetVLAD 对语句长度不敏感的原因是相同的。
- 在基于 Bi-LSTM+ATT 的模型中，随着句子长度增加，模型效果都产生较

大但也十分一致的波动。其中 Bi-LSTM+ATT 和 Bi-LSTM+max+ATT 的下降值也达到了 4 个百分点。基于单词级别注意力机制的模型变化较小，约为 2.3 个百分点，甚至在语句长度从 30 增加到 40 时还有一定的效果提升。

4.3.2 聚类中心数目

相比于其他模型，RE_NetVLAD 拥有着独特的超参数，聚类中心数目 K 。为了评估模型的稳定性和可靠性，我们对于这一超参数进行了如下实验，即在大范围内改变 K 的值，观察模型最终的效果，实验结果如表4.3和图4.11所示：

表 4.3 聚类中心数目 K 的大小对于 RE_NetVLAD 效果的影响。

多语句编码器	ATT				
P@N(%)	100	200	300	Mean	GAP
cluster 2	80.0	76.5	74.0	76.8	36.5
cluster 10	82.0	78.0	74.0	78.0	40.5
cluster 20	73.0	69.5	67.7	70.1	37.7
cluster 50	80.0	76.5	72.7	76.4	40.0
cluster 100	82.0	76.0	72.3	76.8	40.0
cluster 150	82.0	75.5	72.0	76.5	40.0
cluster 200	85.0	78.5	73.0	78.8	39.5
cluster 400	80.0	73.0	71.7	74.9	39.5




图 4.11 聚类中心数目对于 RE_NetVLAD 效果的影响。横轴为聚类中心数目，纵轴为 GAP。

可以看出，在聚类中心数目小于 50 的时候，效果有着较大的波动，约为 4 个百分点。随着聚类数目的提高，模型的效果也趋于稳定，上下浮动不超过 1 个百分点。这些实验现象说明 RE_NetVLAD 在关系抽取上的效果对于超参数的设置并不敏感，即 RE_NetVLAD 在关系抽取上取得的效果提升是一致而稳定的。

4.4 聚类的语言学意义探索

在基于人工特征的传统计算机视觉方法里，VLAD 的聚类中心即对应着有具体含义的“视觉词汇”(visual words)，例如眼睛、头发、帽子等，所有的视觉词汇在空间里组成一组衡量基准，所以最后记录下的残差即代表着目标图像与各个视觉词汇的相似度。这个解释在基于神经网络的 NetVLAD 方法中，也得到了验证^[32]。既然 RE_NetVLAD 已经被证明在关系抽取任务上取得极具竞争力而且十分稳定的效果增益，我们也遵循相同的思路，尝试对 RE_NetVLAD 中的聚类中心背后的语言学意义进行探索。

方便起见，我们选用了聚类中心数目为 2 的 RE_NetVLAD 模型，并观察语句中每个单词在两个聚类中心上的概率分布，并选取概率较大的那个做为该单词对应的聚类中心。结果发现，除了两个目标实体以及少量可能对关系预测有帮助的单词被分到第二个聚类中心外，其他单词都被分到第一个聚类中心，如表A-3中所展示的例子并不少见，其中语句中聚类分布的表示方法为：**粗体**代表该词语归属第二个聚类中心，否则为第一个。对于部分虽然不归属第二个聚类中心，但权值较大(>0.1)的词语，我们将这些词进行了倾斜表示并在后面用括号的形式标出了其归属第二个聚类中心的概率值，其余未标示词语归属第二个聚类中心的权值均小于 0.1。很显然，这些聚类有着明显的符合实际的语言学意义。

为了进一步探寻聚类的实际意义，我们也在聚类中心数目为 50 的 RE_NetVLAD 模型上进行了进一步的实验，即将每个聚类中心对应的权值较大的词语进行了展示，可以看到在语义上，同一个聚类中心对应的单词都有着相似的主题，并暗示着一类关系分布，结果如表4.5所示，例如第 3 个聚类中心对应的几乎全部是地理位置的名称，第 38 个对应的多为人的社会关系和角色名称等。

表 4.4 语句中不同单词对应的聚类中心的分布。

关系类型	语句中聚类分布
/location/contains	after studying computer science <i>at</i> (0.12) the university_of_pennsylvania in philadelphia , yang took a <i>job</i> (0.14) as a <i>software</i> (0.1) engineer at an <i>investment</i> (0.37) firm downtown ...
/person/children	he UNK got a great <i>father</i> (0.17), barber said, referring <i>to</i> (0.1) archie_manning , whose UNK career as an UNK quarterback ...
/company/place_founded	the president <i>of</i> (0.15) universal_studios , who <i>came</i> (0.2) <i>from</i> (0.38) los_angeles ...
/location/neighborhood	...from carroll_gardens to the west, is being touted as the next brooklyn neighborhood (0.48) ...

表 4.5 不同的聚类中心对应的单词及其权重。

聚类中心 ID	对应的单词及其权重
3	sri_lanka (0.95), west_virginia (0.95), belgium (0.94), italy (0.94), scotland (0.93), texas (0.93) ...
28	karl_lagerfeld (0.95), sumner_redstone (0.95), levi_strauss (0.95), medgar_evers (0.94), william_eggleston (0.94) ...
5	mother (0.73), doctorate(0.68), childhood (0.59), graduate (0.57), child (0.55), doctor (0.52), adolescent (0.48) ...
47	christian (0.95), sundays (0.92), muslim (0.85), islamic (0.83), jihad (0.80), sermons (0.78), hasidic (0.73), jesus (0.68) ...
38	son (0.75), principal (0.74), founder (0.63), bridegroom (0.61), partner (0.60), billionaire (0.58), daughter (0.46), dean (0.44) ...

第 5 章 文章结论与未来工作

在本篇论文中，我们首先对现有的神经关系抽取模型进行了综述，并选取其中数个主流模型进行了自主实现。考虑到单语句较长的富语境情形，我们提出了新型的单语句编码器 RE_NetVLAD，由于其可以很好地表示语句中的局部信息，所以在一个大规模的面向关系抽取的公开数据上，取得了目前最好的单模型效果，并在不同的设定下，都能在测试效果和训练效率上给出极具竞争力的表现。通过对语句长度和超参数的实验证明，RE_NetVLAD 模型的效果是一致而且稳定的，对于语句长度和超参数的变化都具有很强的鲁棒性。最后对于聚类中心的案例研究表明模型中学习到的聚类中心是包含着实际的语言学意义。

针对实验现象，我们未来的工作主要分为如下几部分：

- 在现有工程的基础上，进一步优化与扩展，建立一个统一的包含主流模型的可复现的神经关系抽取模型框架，为后来研究者学术上的跟进提供便利。
- 继续探究 RE_NetVLAD 的聚类中心对应的语言学意义。文章中只考虑了两种极为有限的特殊情况，但即便如此，模型依然可以表现出极强的表示学习能力，将实体对和对判断关系类型有帮助的单词赋予很高的权重。当聚类中心数目扩展到更多的时候，是否能像计算机视觉中的“视觉词汇”一样，表现出“核心语言概念”的能力？这个问题值得进一步探究。
- 探究神经网络参数、深度与抽取效果的关系。实验中，ResCNN 以及 word_att 都有着更深的网络以及更多的参数，但事实证明并没有办法带来效果上的增益。为何不像计算机视觉任务中体现的一样，更深的网络可以得到更好的特征，从而帮助分类？
- 探究如何将 RE_NetVLAD 方法与现有的单语句编码器相结合。RE_NetVLAD 除了可以本身当做单语句编码器外，还可以作为一种特殊的池化层加入到现有的编码器如 CNN、LSTM 的输出上。经验上深层的特征相比浅层特征具有更丰富的表达能力，所以在更深层的特征上的池化，预期是可以取得更好的效果。但实验证明简单的将两者结合，只会让效果更差。如何有效地进行结合从而带来效果上的增益，是一个值得探究的问题。

参考文献

- [1] Mintz M, Bills S, Snow R, et al. Distant supervision for relation extraction without labeled data[C]//Proceedings of ACL-IJCNLP. [S.l.: s.n.], 2009: 1003-1011.
- [2] Riedel S, Yao L, McCallum A. Modeling relations and their mentions without labeled text [M]//Proceedings of ECML-PKDD. [S.l.: s.n.], 2010: 148-163
- [3] Hoffmann R, Zhang C, Ling X, et al. Knowledge-based weak supervision for information extraction of overlapping relations[C]//Proceedings of ACL-HLT. [S.l.: s.n.], 2011: 541-550.
- [4] Hong G. Relation extraction using support vector machine[C]//International Conference on Natural Language Processing. [S.l.]: Springer, 2005: 366-377.
- [5] Yu X, Lam W. Jointly identifying entities and extracting relations in encyclopedia text via a graphical model approach[C]//Proceedings of the 23rd International Conference on Computational Linguistics: Posters. [S.l.]: Association for Computational Linguistics, 2010: 1399-1407.
- [6] Peng M, Huang J, Sun Z, et al. Improving distant supervision of relation extraction with unsupervised methods[C]//International Conference on Web Information Systems Engineering. [S.l.]: Springer, 2016: 561-568.
- [7] Lin Y, Shen S, Liu Z, et al. Neural relation extraction with selective attention over instances [C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers): volume 1. [S.l.: s.n.], 2016: 2124-2133.
- [8] Huang G, Liu Z, Weinberger K Q, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition: volume 1. [S.l.: s.n.], 2017: 3.
- [9] Dahl G E, Yu D, Deng L, et al. Context-dependent pre-trained deep neural networks for large-vocabulary speech recognition[J]. IEEE Transactions on audio, speech, and language processing, 2012, 20(1): 30-42.
- [10] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [11] Serban I V, Sordoni A, Bengio Y, et al. Building end-to-end dialogue systems using generative hierarchical neural network models.[C]//AAAI: volume 16. [S.l.: s.n.], 2016: 3776-3784.
- [12] Socher R, Huval B, Manning C D, et al. Semantic compositionality through recursive matrix-vector spaces[C]//Proceedings of the 2012 joint conference on empirical methods in natural language processing and computational natural language learning. [S.l.]: Association for Computational Linguistics, 2012: 1201-1211.

- [13] Zeng D, Liu K, Chen Y, et al. Distant supervision for relation extraction via piecewise convolutional neural networks[C]//Proceedings of EMNLP. [S.l.: s.n.], 2015.
- [14] Xu Y, Mou L, Li G, et al. Classifying relations via long short term memory networks along shortest dependency paths[C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. [S.l.: s.n.], 2015: 1785-1794.
- [15] Miwa M, Bansal M. End-to-end relation extraction using lstms on sequences and tree structures [J]. arXiv preprint arXiv:1601.00770, 2016.
- [16] Huang Y Y, Wang W Y. Deep residual learning for weakly-supervised relation extraction[J]. arXiv preprint arXiv:1707.08866, 2017.
- [17] Bengio Y. Learning deep architectures for ai[J]. Foundations and trends® in Machine Learning, 2009, 2(1): 1-127.
- [18] Mikolov T, Sutskever I, Chen K, et al. Distributed representations of words and phrases and their compositionality[C]//Proceedings of NIPS. [S.l.: s.n.], 2013: 3111-3119.
- [19] Zeng D, Liu K, Lai S, et al. Relation classification via convolutional deep neural network[C]//Proceedings of COLING. [S.l.: s.n.], 2014: 2335-2344.
- [20] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l.: s.n.], 2016: 770-778.
- [21] Zhang D, Wang D. Relation classification via recurrent neural network[J]. arXiv preprint arXiv:1508.01006, 2015.
- [22] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [23] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [24] Xu K, Feng Y, Huang S, et al. Semantic relation classification via convolutional neural networks with simple negative sampling[J]. arXiv preprint arXiv:1506.07650, 2015.
- [25] Tai K S, Socher R, Manning C D. Improved semantic representations from tree-structured long short-term memory networks[C]//Proceedings of ACL. [S.l.: s.n.], 2015: 1556-1566.
- [26] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60(2): 91-110.
- [27] Csurka G, Dance C, Fan L, et al. Visual categorization with bags of keypoints[C]//Workshop on statistical learning in computer vision, ECCV: volume 1. [S.l.]: Prague, 2004: 1-2.
- [28] Perronnin F, Dance C. Fisher kernels on visual vocabularies for image categorization[C]//Computer Vision and Pattern Recognition, 2007. CVPR'07. IEEE Conference on. [S.l.]: IEEE, 2007: 1-8.
- [29] Jégou H, Douze M, Schmid C, et al. Aggregating local descriptors into a compact image representation[C]//Computer Vision and Pattern Recognition (CVPR), 2010 IEEE Conference on. [S.l.]: IEEE, 2010: 3304-3311.

- [30] Arandjelovic R, Zisserman A. All about vlad[C]//Computer Vision and Pattern Recognition (CVPR), 2013 IEEE Conference on. [S.l.]: IEEE, 2013: 1578-1585.
- [31] Arandjelovic R, Gronat P, Torii A, et al. Netvlad: Cnn architecture for weakly supervised place recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. [S.l.: s.n.], 2016: 5297-5307.
- [32] Girdhar R, Ramanan D, Gupta A, et al. Actionvlad: Learning spatio-temporal aggregation for action classification[C]//CVPR: volume 2. [S.l.: s.n.], 2017: 3.
- [33] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv:1502.03167, 2015.
- [34] Zhou P, Shi W, Tian J, et al. Attention-based bidirectional long short-term memory networks for relation classification[C]//Proceedings of ACL. [S.l.: s.n.], 2016: 207.

致 谢

衷心感谢我的学术导师也是人生导师，敬爱的刘知远副教授在过去的两年时间内对我的指导与关心。正是在刘导的帮助和引导下，我才有机会以一个非计算机系学生的身份接触自然语言处理和机器学习相关的知识与科研，从而感受到了探索人工智能科学的难以言表的无限乐趣，也坚定了继续攻读相关方向博士的信念与决心。同时刘导身体力行所倡导的科研作风，使我认识到什么才是真正有价值的科研工作。除了学术本身外，刘导在人生道路的选择上也给予了我很多珍贵的经验，并在我最困难最迷茫的时候去了解我内心所纠结的地方，给予了宝贵的理解与帮助。

感谢实验室的林衍凯师兄和韩旭师兄，以及已经远在异国的曾文远、吴佳炜学长，正是你们的帮助和鼓励使我鼓起勇气克服了一个又一个科研上的困难。感谢实验室的辛极、王子云和朱昊同学，正是同你们的交流和沟通，带给了我无限的灵感和继续前进的动力，同时也让我感受到自己并不孤单。

感谢清华大学和物理系对我的培养，正是得益于数理基础科学班独特的培养方案，使我能够在扎实的学好数学物理基础知识的同时，可以根据兴趣去从事自己热爱的科研方向，虽然这种自由度也曾一度带给我痛苦的迷茫，但也正是因为这些迷茫的时期，使我真正意识到了自己想要什么样的生活，并为此而奋斗。

感谢我的爸爸，我的妈妈还有我的姐姐，二十年来你们给予了我无限的支持与帮助，使我一步步长大成人并走到今天。正是在你们的教育下，我才可以拥有这个世界上最宝贵的品质：善良、正直、勇敢与坚强。

感谢那个有些幼稚甚至固执，但为了理想从不服输和妥协并一直努力坚持奋斗着，活在我内心的还没长大的小男孩，在我每次想要放弃的时候都给予我继续前进的动力，希望我们能在未来一起走的更远。

衷心感谢所有给予我帮助和支持的人，我希望我也相信，未来我可以用我的实际行动证明我没有辜负你们的期望与信任。

最后我想以《了不起的盖茨比》中的一段话来结尾：So we beat on, boats against the current, borne back ceaselessly into the past.

愿我们每个人都能成为自己的英雄。

声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____

插图索引

图 2.1	带有最大池化层和非线性层的卷积神经网络 (CNN) 编码器。.....8
图 2.2	残差网络 (ResNet) 结构 ^[20] 中的跳跃式连接 (skip connection)。可以使得网络在变深的时候, 梯度可以更好地进行回传, 从而加速网络的训练, 并提升训练效果。.....9
图 2.3	带有最大池化层的双向循环神经网络 (Bi-RNN) 结构。.....9
图 2.4	基于句法依存树的 LSTM 网络结构。其中带有箭头的实线表示依存树上的最短路径。带有箭头的虚线表示向量的输出方向。..... 11
图 2.5	矩阵-向量递归神经网络模型结构。每个词都有向量和矩阵两种表示方法。带有箭头的实线表示语法依存树上的路径。..... 12
图 3.1	最大池化和平均池化方法与 VLAD 的对比。a, b, c 依次为最大池化, 平均池化和 VLAD。图中不同颜色的点代表不同子区域的局部特征向量, 五角星在 a、b 中代表池化后的最终表示向量, 在 c 中代表聚类中心。..... 16
图 3.2	相比于原始 VLAD, 有监督学习下的 NetVLAD 拥有更强的表达能力, 可以处理更复杂的情况 ^[31] 。例如上图中, 红点和绿点都是局部特征向量, 但属于两个不同类别的训练样例, 但都归属在同一个聚类区域 (图中的多边形框), 聚类中心为 $\mathbf{c}_k$ 。两个训练样例的最终表示向量的相似度由两者残差向量的内积所决定。在原始 VLAD 中, 聚类中心即 (近似) 为该聚类区域的中心 $\mathbf{c}_k^{VLAD}$ ($\times$)。但是在有监督学习的 NetVLAD 中, 可以得知两个训练样例并不属于同一类别, 就有可能学习到一个更好的聚类中心 $\mathbf{c}_k^{NetVLAD}$ ($\star$), 使得两者的残差向量的内积更小。..... 17
图 3.3	聚类中心数目为 2 的 RE_NetVLAD 网络结构。..... 19
图 4.1	基于 CNN+AVG 的模型族在测试集上的准确率-召回率曲线 (最好在有颜色的环境下观看)。..... 22
图 4.2	基于 CNN+ATT 的模型族在测试集上的准确率-召回率曲线 (最好在有颜色的环境下观看)。..... 23

图 4.3	基于 Bi-LSTM+AVG 的模型族在测试集上的准确率-召回率曲线 (最好在有颜色的环境下观看)。	23
图 4.4	基于 Bi-LSTM+ATT 的模型族在测试集上的准确率-召回率曲线 (最好在有颜色的环境下观看)。	24
图 4.5	训练集中平均单语句长度的概率密度分布函数。横坐标为句子长度, 纵坐标为长度在此区间内的句子数占总数的百分比。	26
图 4.6	测试集中平均单语句长度的概率密度分布函数。图例同左。	26
图 4.7	训练集中平均单语句长度的数目分布。纵坐标为句子长度,横坐标 为长度小于等于纵坐标的句子数目。	27
图 4.8	训练集中平均单语句长度的数目分布。图例同左。	27
图 4.9	基于 CNN+ATT 的模型族在测试集上的 GAP 指标与最大平均语句 长度阈值的关系(最好在有颜色的环境下观看)。横坐标为最大平均 语句长度的阈值,纵坐标为 GAP。	27
图 4.10	基于 Bi-LSTM+ATT 的模型族在测试集上的 GAP 指标与最大平均 语句长度阈值的关系(最好在有颜色的环境下观看)。图例同上。	28
图 4.11	聚类中心数目对于 RE_NetVLAD 效果的影响。横轴为聚类中心数 目,纵轴为 GAP。	29
图 A-1	基于语句级别注意力机制的卷积神经网络模型,其中 x_i 和 $\mathbf{x}_i$ 分别 表示其原始的语句字符串和它对应的经过卷积神经网络后得到的 输出也就是其向量化的表示, α_i 是由注意力机制模型分配给这个 句子的权重, $\mathbf{s}$ 表示这对实体对对应的句子集合的向量化表示。	44
图 A-2	语句编码器 CNN/PCNN 的神经网络结构。	47
图 A-3	上方: CNN, CNN+ONE, CNN+AVE, CNN+ATT 模型的准确率-召 回率曲线。下方: PCNN, PCNN+ONE, PCNN+AVE, PCNN+ATT 模 型的准确率-召回率曲线。	57
图 A-4	与基于人工特征的方法的性能比较。	58

表格索引

表 4.1	不同模型的超参数设置。	21
表 4.2	RE_NetVLAD 与基线模型的效果比较。	22
表 4.3	聚类中心数目 K 的大小对于 RE_NetVLAD 效果的影响。	29
表 4.4	语句中不同单词对应的聚类中心的分布。	31
表 4.5	不同的聚类中心对应的单词及其权重。	31
表 A-1	模型超参数设置。	52
表 A-2	对于拥有不同句子数目的实体对的关系抽取方法的 $P@N$ 指标。	53
表 A-3	NYT 语料上选择性注意力机制的例子。	56

公式索引

公式 2-1	7
公式 2-2	8
公式 2-3	9
公式 2-4	9
公式 2-5	10
公式 2-6	10
公式 2-7	10
公式 2-8	10
公式 2-9	10
公式 2-10	10
公式 2-11	10
公式 2-12	10
公式 2-13	11
公式 2-14	11
公式 2-15	11
公式 2-16	11
公式 2-17	11
公式 2-18	11
公式 2-19	12
公式 2-20	12
公式 2-21	12
公式 2-22	12
公式 2-23	13
公式 2-24	13
公式 2-25	13
公式 2-26	13
公式 2-27	14
公式 2-28	14

公式 2-29	14
公式 3-1	15
公式 3-2	16
公式 3-3	17
公式 3-4	17
公式 3-5	18
公式 3-6	18
公式 3-7	18
公式 3-8	18
公式 3-9	18
公式 3-10	18
公式 4-1	20
公式 A-1	48
公式 A-2	49
公式 A-3	49
公式 A-4	49
公式 A-5	49
公式 A-6	49
公式 A-7	50
公式 A-8	50
公式 A-9	50
公式 A-10	50
公式 A-11	50
公式 A-12	51

附录 A 外文资料的书面翻译

基于选择性注意力机制的神经关系抽取

摘要：基于远程监督的关系抽取已被广泛用于从文本中找到新的关系事实。然而，远程监督不可避免地会带来错误的标注，这些有噪音的数据将极大地损害关系抽取的效果和性能。为了解决这个问题，我们提出了一个基于句子级别注意力机制的关系抽取模型。在这个模型中，我们首先使用卷积神经网络来表示语句的语义。之后，我们在多个语句实例上构建句子级别的注意力机制，这样可以动态减少那些噪音实例的权重。在真实世界数据集上的实验结果表明，我们的模型可以充分利用所有有真实信息量的句子，并有效减少错误标注实例的影响。与基线模型相比，我们的模型在关系提取方面取得了显著且一致的改进。本文的源代码可以从<https://github.com/thunlp/NRE>获得。

A.1 引言

近些年来,Freebase^[1],DBpedia^[2]和YAGO^[3]等各种大型知识库(KB)或知识图谱已经逐渐被建立并被广泛应用于许多自然语言处理(NLP)任务包括网页搜索和问答系统。这些知识库主要由三元组形式的关系事实组成,例如(*Microsoft*, *founder*, *Bill Gates*)。虽然现有的知识库已经包含大量的事实,但与现实世界中的无穷无尽的知识相比,它们还远远不够完整。为了丰富知识库,研究者们已经投入了很多努力来寻找可以自动发现未知的关系事实的方法。因此,关系抽取(RE),即从未经标注的纯文本中生成关系事实的过程,是NLP中的关键任务。

大多数现有的有监督的关系抽取系统需要大量的经过人工标记好关系类型的训练数据,这需要很长的时间且耗费人力。因此,^[4]提出了远程监督的方法,通过对齐知识库中已有的关系三元组和未经标注的文本自动生成训练数据。他们假设如果两个实体在知识库中有关系,那么包含这两个实体的所有句子将表达这种关系。例如,(*Microsoft*, *founder*, *Bill Gates*)是KB中的关系事实。远程监督将把包含这两个实体的所有句子视为relation founder训练实例。虽然这一远程监督策略是自动标记训练数据的有效策略,但它总会产生错误标注

的问题。例如，“比尔盖茨转向慈善事业与微软在美国和欧盟的反托拉斯问题有关。”这句话并不表达创建者的关系，但仍将被视为一个有效的训练实例。因此，^[5-7] 采用多实例学习方法来尝试解决错误标注的问题。这些传统方法的主要缺点是大多数特征都是从 NLP 工具（如 POS 标记）中显示的表示出的，所以这些 NLP 工具生成的错误将在这些方法中继续迭代以至于可能生成进一步的错误预测。




图 A-1 基于语句级别注意力机制的卷积神经网络模型，其中 x_i 和 $\mathbf{x}_i$ 分别表示其原始的语句字符串和它对应的经过卷积神经网络后得到的输出也就是其向量化表示， α_i 是由注意力机制模型分配给这个句子的权重， $\mathbf{s}$ 表示这对实体对对应的句子集合的向量化表示。

最近的一些工作^[8-10] 试图放弃基于人工特征的关系抽取方法，转而使用深层神经网络提取特征。这些方法基于语句级别的标注数据构建分类器，但由于缺乏人工标注的训练数据，因此无法应用于大规模的知识库构建。因此，^[11] 将多实例学习与神经网络模型相结合，可以建立基于远程监督所构建的数据集的关系抽取方法。尽管该方法在关系提取方面取得了显著的效果提高，但仍然远远不能令人满意。该方法假设在所有包含两个实体的句子中，至少有一个句子能够表达它们之间的关系，并且在训练和预测两个阶段仅使用每个实体对所对应

的概率最高也就是最有可能正确表达其关系的句子。很明显，这种方法将会丢失大量被忽略的句子中的丰富的有用的信息。

在本文中，我们提出了一种基于语句级别注意力机制的卷积神经网络（CNN）模型，用于基于远程监督的关系提取。如图A-1所示，我们使用 CNN 来提取语句的特征并用向量来表示。之后，为了充分利用包含所有信息的句子，我们将关系表示为所有句子向量的线性组成。为了解决错误标注的问题，我们在多个句子实例上构建语句级别的注意力模型，从而动态地减少这些包含噪音的实例所对应的权重。最后，我们将通过注意力机制得到的加权求和过的句子向量作为实体对所对应的特征向量，并将其用于关系分类。我们在来源于真实世界的关系抽取数据集上评估了我们的模型。实验结果表明，与当前最先进的方法相比，我们的模型在关系提取方面取得了显著和一致的改进。

这篇文章的主要贡献可以总结为如下几个方面：

- 和现有的基于神经网络的关系抽取方法相比，我们的模型可以更加充分更加全面地利用目标实体对所对应的所有句子。
- 为了解决远程监督所带来的错误标注问题，我们提出了语句级别的注意力机制模型，可以有效地动态地降低噪音例子所对应的权重，从而大大降低因为错误标注带来的错误可能性。
- 在实验部分，我们展示了我们所提出的注意力机制模型对于目前常用的两种针对关系抽取的卷积神经网络模型都是有所帮助的。

A.2 相关研究工作

关系抽取是 NLP 中最重要的任务之一。之前的研究人员已经在关系抽取方面做了很多努力，特别是在有监督的关系抽取方面。这些方法中的大多数都需要大量的标注数据，这需要耗费大量的时间和人力物力。为了解决这个问题，^[4]通过远程监督方法将纯文本与 **Freebase** 数据库进行语料对齐。然而，远程监督不可避免地会造成错误标注的问题。为了解决这一问题，^[5]将基于远程监督的关系抽取问题模型化为多实例单标签问题，一个经典的机器学习问题，之后^[6-7]更进一步，将其拓展为多实例多标签学习。最初提出多实例学习是为了解决预测药物活性时训练数据标注过于模糊的问题。多实例学习考虑每个实例的标注的准确性。^[12]将弱监督学习与多实例学习相结合，并将其扩展到关系抽取。但是所有基于人工特征的方法由于强烈依赖于 NLP 工具生成的特征的质量，所以也都

遇到了特征标注错误的叠加和传播的问题。

近年来,深度学习^[13]已广泛应用于各个领域,包括计算机视觉,语音识别等。它还被成功应用于不同的 NLP 任务,如词性标注^[14],情感分析^[15],句法分析^[16]和机器翻译^[17]。由于最近在深度学习方面的成功,许多研究人员已经开始尝试使用神经网络来提取特征用于关系抽取。^[8]在关系提取中使用了递归神经网络(RNN)。他们首先对句子进行句法分析,然后将语法树中的每个节点表示为一个向量。此外,^[9-10]采用端到端的卷积神经网络(CNN)进行关系抽取。此外,^[18]尝试将实体的文本信息添加到关系抽取中。

尽管这些方法已经取得了很大的成功,他们仍然都是在单个句子上进行抽取,并且深受训练数据匮乏之苦。另外,传统方法中的多实例学习策略不能被轻易地应用于神经网络模型。因此,^[11]将非单实例学习(实例数大于等于1)与神经网络模型相结合以进行基于远程监督的关系抽取。但是,他们假设每个实体对所以对应的语句集合中只有一个句子是有效的。因此,它将缺失大量包含在那些被忽略的句子中的丰富信息。与他们的方法不同,我们提出面向多个实例的语句级别注意力机制,这可以充分有效地利用所有句子的信息。

注意力机制模型近来引起了研究人员的广泛兴趣。基于注意力机制的模型使得不同模态之间的对齐成为了可能。它已被广泛应用于各种领域,如图像分类^[19],语音识别^[20],图像标题生成^[21]和机器翻译^[22]。就我们所知,我们提出的方法是在基于远程监督的关系抽取领域中采用基于注意力机制的模型的第一次尝试。

A.3 方法

给定一个语句集合 $\{x_1, x_2, \dots, x_n\}$ 和两个相应的实体,我们的模型预测每个关系 r 的概率。在本节中,我们将主要分为如下两个部分介绍我们的模型:

- **语句编码器** 给定一个句子 x 和两个目标实体,我们用一个卷积神经网络来提取句子 $\mathbf{x}$ 的分布式表示特征。
- **基于多样例的注意力机制**. 当所有句子的分布式表示向量被学习到后,我们使用语句级别的注意力机制模型来选择那些真正表达了对应的关系的语句。




图 A-2 语句编码器 CNN/PCNN 的神经网络结构。

A.3.1 语句编码器

如图A-2所示, 我们通过卷积神经网络 (CNN) 将句子 x 转换成它所对应的分布式向量表示 $\mathbf{x}$ 。首先, 将句子中的单词转换为稠密的实值特征向量, 即所对应的词向量表示。接下来分别使用卷积层、最大池化层和非线性变换层来构造语句的分布式表示, 即 $\mathbf{x}$ 。

A.3.1.1 输入表示

CNN 的输入是句子 x 的原始单词。我们首先将单词转换成低维向量, 这里, 通过词嵌入矩阵将每个输入词变换成了其所对应的词向量。另外, 为了表示每个实体对在句子中所处的位置, 我们还对句子中的所有单词的相对位置进行了嵌入向量化表示。

单词嵌入向量表示 单词嵌入向量表示旨在将单词转换为分布式表示，从而捕捉到单词所对应的句法和语义含义。给定一个句子 x ，其组成为 m 个单词，即 $x = \{w_1, w_2, \dots, w_m\}$ ，每个单词 w_i 由一个实值向量所表示，即所对应的词向量。词的向量化表示由嵌入向量矩阵 $\mathbf{V} \in \mathbb{R}^{d^a \times |V|}$ 中的列向量编码，其中 V 是一个固定大小的词汇表。

单词位置嵌入向量表示 在关系抽取任务中，一般情况下，靠近目标实体的单词通常都是富含有用的信息的，对确定目标实体对的关系是有帮助的。类似于^[9]中的处理方法，我们使用了以目标实体对为位置基准的单词位置嵌入向量表示。它可以帮助 CNN 去观察每个词相对于目标实体单词的相对距离。它也因此被定义为相对于头部实体和尾部实体的相对距离的组合。例如，在句子 “Bill_Gates is the founder of Microsoft.” 中，单词 “founder” 相对于头部实体 *Bill_Gates* 的相对距离为 3，相对于尾部实体 *Microsoft* 的相对距离为 2。

在图A-2中所展示的例子中，它假定单词嵌入向量的维度 d^a 为 3，单词位置嵌入向量的维度 d^b 为 1。最后，我们将每个单词的嵌入向量和位置嵌入向量拼接起来然后把整句话表示成如下的向量序列， $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m\}$ ，其中 $\mathbf{w}_i \in \mathbb{R}^d (d = d^a + d^b \times 2)$ 。

A.3.1.2 卷积层，最大池化层和非线性变换层

在关系提取中，主要的挑战是句子的长度是可变的，重要的信息可以出现在句子的任何区域。因此，我们应该利用所有局部特征来进行全局关系预测。在这里，我们使用卷积操作来合并所有这些特征。在卷积层中，先用一个长度为 l 的滑动窗口在所有句子上提取局部特征。在如图A-2所展示的例子中，我们假设滑动窗口的大小 l 为 3。然后，通过一个最大池化操作，将所有局部特征合并成一个固定长度大小的特征向量，来表示输入的句子。

在这里，卷积操作被定义为一个向量序列 $\mathbf{w}$ 和卷积核矩阵 $\mathbf{W} \in \mathbb{R}^{d^c \times (l \times d)}$ 间进行的矩阵乘法操作，其中 d^c 是句子特征向量的维度大小。我们定义 $\mathbf{q}_i \in \mathbb{R}^{l \times d}$ 为第 i 个滑动窗口内的单词的嵌入向量的拼接。即：

$$\mathbf{q}_i = \mathbf{w}_{i-l+1:i} \quad (1 \leq i \leq m + l - 1). \quad (\text{A-1})$$

由于在滑动窗口从左至右滑动时，可能会超出句子的范围（因为句子的长度是不确定的），所以对于超出的范围，我们统一使用零向量来进行填充。即将所有超出范围的输入向量 $\mathbf{w}_i (i < 1 \text{ or } i > m)$ 统一视为零向量。

因此，卷积层的第 i 个卷积输出为：

$$\mathbf{p}_i = [\mathbf{W}\mathbf{q} + \mathbf{b}]_i \quad (\text{A-2})$$

其中 $\mathbf{b}$ 是一个偏置向量。向量 $\mathbf{x} \in \mathbb{R}^{d^c}$ 的第 i 维通过如下最大池化操作得到：

$$[\mathbf{x}]_i = \max(\mathbf{p}_i), \quad (\text{A-3})$$

此外，CNN 的一种变体，PCNN^[11] 采用了分段池化操作来进行关系抽取。每个卷积核 $\mathbf{p}_i$ 被头部实体和尾部实体分成了三部分： $(\mathbf{p}_{i1}, \mathbf{p}_{i2}, \mathbf{p}_{i3})$ 。最大池化操作也相应地在三部分上分别进行，即：

$$[\mathbf{x}]_{ij} = \max(\mathbf{p}_{ij}), \quad (\text{A-4})$$

其中 $[\mathbf{x}]_i$ 被定义为向量 $[\mathbf{x}]_{ij}$ 的拼接。

最后，我们在得到的向量上应用非线性函数，如双曲正切。

A.3.2 面向多实例的注意力机制

假设有一个集合 S 包含了 n 个句子，每个句子都包含实体对 $(head, tail)$ ，即 $S = \{x_1, x_2, \dots, x_n\}$ 。

在预测关系 r 是否存在时，为了充分利用所有句子的信息，我们的模型将集合 S 表示成了一个实值向量 $\mathbf{s}$ 。很显然，集合 S 的表示依赖于所有句子的表示 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 。每个句子的表示 $\mathbf{x}_i$ 都或多或少的含有一些信息，这些信息决定了头部实体和尾部实体对 $(head, tail)$ 是否可以在语义上表示关系 r 。

集合的表示向量 $\mathbf{s}$ 可以通过这些句子向量 $\mathbf{x}_i$ 的加权平均来计算得到：

$$\mathbf{s} = \sum_i \alpha_i \mathbf{x}_i, \quad (\text{A-5})$$

其中 α_i 表示句子向量 $\mathbf{x}_i$ 的权重。在本篇论文中，我们有两种定义 α_i 的方式，即：

平均值 我们假设集合 X 中的所有句子对集合的表示具有相同的贡献。这意味着集合 S 的嵌入式向量表示是所有句子向量的简单平均值：

$$\mathbf{s} = \sum_i \frac{1}{n} \mathbf{x}_i, \quad (\text{A-6})$$

这也是本文中的一个基线模型。

选择性注意力机制 然而，在实际情况中，远程极端会不可避免地会带来错误标注的问题。因此，如果我们平等地看待每个句子，那么含有错误标签的句子

在训练和测试中会带来大量的噪音。因此，我们使用有选择性注意力机制去减少含有噪音的句子所对应的权重值。此时 α_i 也就相应地被定义为：

$$\alpha_i = \frac{\exp(e_i)}{\sum_k \exp(e_k)}, \quad (\text{A-7})$$

其中 e_i 是一个查询函数，通过这个它，我们可以表示输入的语句 x_i 和想要预测的关系类型 r 在多大程度上是匹配的，即输入语句 x_i 在多大程度上可以表现关系 r 。之后，我们选择了在实验中表现效果最好的双线性函数作为计算 e_i 的函数：

$$e_i = \mathbf{x}_i \mathbf{A} \mathbf{r}, \quad (\text{A-8})$$

其中 $\mathbf{A}$ 是一个对角矩阵，对角线元素表示了权重。 $\mathbf{r}$ 是和关系类型 r 相对应的查询向量，也就是关系类型 r 的向量化表示，即特征向量。

最后我们通过一个 softmax 层来计算条件概率 $p(r|S, \theta)$ ，即：

$$p(r|S, \theta) = \frac{\exp(o_r)}{\sum_{k=1}^{n_r} \exp(o_k)}, \quad (\text{A-9})$$

其中 n_r 是关系类型的总数量， $\mathbf{o}$ 是神经网络的最终输出向量，它表示了对所有关系类型的预测分数，定义如下所示：

$$\mathbf{o} = \mathbf{M} \mathbf{s} + \mathbf{d}, \quad (\text{A-10})$$

其中 $\mathbf{d} \in \mathbb{R}^{n_r}$ 是偏置向量， $\mathbf{M}$ 是所有关系类型的表示矩阵（即所有关系类型对应的特征向量所构成的矩阵）。

^[11] 遵循了如下假设：至少有一个包含实体对的句子会反映它们之间的关系，由此为依据，使用且仅使用每个集合中具有最高概率的句子进行训练和预测。因此，他们采用的多实例学习方法可以被视为一种特殊情况，即，当我们的选择性注意力机制对概率最高的句子的权重设置为 1，其他句子权重设为 0 时，两种方法就完全一样了。

A.3.3 优化方法与实现细节

这里我们介绍我们模型的学习过程和优化细节。我们采用交叉熵函数来作为目标函数，即：

$$J(\theta) = \sum_{i=1}^s \log p(r_i | S_i, \theta), \quad (\text{A-11})$$

其中 s 表示句子集合的数量, θ 表示我们模型中所有的可学习参数。为了解决优化问题, 我们采用随机梯度下降 (SGD) 来最小化目标函数。具体训练过程中, 我们每次从训练集中随机选择一个小批量数据进行训练, 并不断迭代, 直到损失函数收敛。

在具体实现中, 我们对于最后的输出层采用了 dropout 操作从而防止过拟合。dropout 层可以定义为输入向量和一个遵从伯努利分布的各维度独立的随机向量 $\mathbf{h}$ 的逐维度向量乘积, 其中伯努利分布的概率值为 p (即每一维度以 p 的概率取 1, $1-p$ 的概率取 0)。则方程 (A-10) 可以被重写为:

$$\mathbf{o} = \mathbf{M}(\mathbf{s} \circ \mathbf{h}) + \mathbf{d}. \quad (\text{A-12})$$

在进行测试的时候, 学习到的集合表示向量尺度上变化了 p 倍, 即 $\hat{\mathbf{s}}_i = p\mathbf{s}_i$ 。经过尺度变换的集合表示向量 $\hat{\mathbf{r}}_i$ 也被用于最终的预测关系类型中去。

A.4 实验部分

我们的实验旨在证明我们的基于语句级别选择性注意力机制的神经网络模型可以在一定程度上解决远程监督带来的错误标注问题, 并充分利用信息量大的句子进行基于远程监督的关系抽取。为此, 我们首先介绍实验中使用的数据集和评测指标。接下来, 我们使用交叉验证来确定我们模型的参数。然后我们评估我们的选择性注意力机制对于最终效果的影响, 并展示在不同规模大小的数据集上的表现。最后, 我们将我们的方法的性能效果与几种最先进的基于人工特征的方法进行了比较分析。

A.4.1 数据集和评测指标

关系抽取任务中,^[5] 开发的数据集被全世界研究者广泛应用, 所以我们也在这个数据集上验证我们的方法。该数据集是通过将 Freebase 知识图谱中的关系类型与纽约时报语料库 (NYT) 进行语料对齐而生成的。实体的标注可以使用斯坦福命名实体标记器^[23] 来进行标注, 并进一步与 Freebase 知识图谱中实体的名称相匹配。Freebase 中的关系类型分为两部分, 一部分用于训练, 一部分用于测试。它将 2005 年到 2006 年的语料库中的句子统一起来, 并将其视为训练实例。测试实例是从 2007 年开始的对齐后的语料。总共有 53 种关系类型, 包括特殊关系 NA 类型, 表示头部和尾部实体之间没有关系。训练数据包含 522,611

个语句, 281,270 个实体对和 18,252 个关系事实。测试集包含 172,448 个句子, 96,678 个实体对和 1,950 个关系事实。

与之前的工作类似^[4], 我们采用相同的评估方法来评估我们的模型。我们通过比较我们模型在测试集中发现的关系事实与 Freebase 中的关系事实来评估我们的模型。它假设测试系统对于 Freebase 内部和外部的关系事实具有相同的性能。因此, 外部评估可以提供近似的精确度量度, 而无需耗费人力来进行评估。我们在我们的实验中报告准确率-召回率曲线和数值指标 Precision@N (P@N)。

A.4.2 实验设置

A.4.2.1 嵌入式词向量设置

在本文中, 我们使用 word2vec 工具^①来训练单词在 NYT 语料库上的嵌入式词向量。我们将在语料库中出现超过 100 次的单词保留为词汇。此外, 当一个实体含有多个单词时, 我们这多个单词拼接成一个单词, 作为这个实体的表示。

A.4.2.2 参数设置

遵循以前的研究工作, 我们使用训练集上的三折交叉验证来调整我们的模型。我们使用网格搜索来确定最优参数, 并在 $\{0.1, 0.01, 0.001, 0.0001\}$ 中选择 SGD 的学习率 λ , 滑动窗口大小的选择范围为 $l \in \{1, 2, 3, \dots, 8\}$, 在 $\{50, 60, \dots, 300\}$ 选择语句嵌入向量的维度大小 n , 以及在 $\{40, 160, 640, 1280\}$ 中选择训练批次大小 B 。对于其他参数, 因为它们对结果影响不大, 所以我们按照^[9]中使用的参数值进行设置。对于训练, 我们将所有训练数据的迭代次数设置为 25。在表A-1中, 我们具体展示了实验中使用的超参数。

表 A-1 模型超参数设置。

Window size l	3
Sentence embedding size d^c	230
Word dimension d^a	50
Position dimension d^b	5
Batch size B	160
Learning rate λ	0.01
Dropout probability p	0.5

① <https://code.google.com/p/word2vec/>

A.4.3 语句级别选择性注意力机制的有效性验证

为了证明语句级别选择性注意力机制的有效性，我们通过实证检验来比较不同的方法的效果。我们选择^[9]中提出的 CNN 模型和^[11]中提出的 PCNN 模型作为我们的句子编码器，并自己实现了它们，以达到与作者报告相当的结果。我们将两种不同类型的 CNN 与句子级别注意力机制（ATT），其基线版本（AVE）（该版本中，每个句子集合的向量表示为集合内部句子的平均向量）以及，多实例学习（至少一个实例）（ONE）^[11] 的表现进行了比较。

从图A-3，我们可以得到如下观察结果：（1）对于 CNN 和 PCNN，ONE 方法与 CNN/PCNN 相比具有更好的性能。原因在于原始的基于远程监督得到的训练数据中包含大量的噪音，而噪音数据会损害关系抽取的性能。（2）对于 CNN 和 PCNN，与 CNN/PCNN 相比，AVE 方法对于关系抽取是有用的。这表明考虑更多的句子有利于关系抽取，因为噪音可以通过信息的互补来减少负面影响。（3）对于 CNN 和 PCNN，AVE 方法与 ONE 方法相比具有相似的性能。这说明，尽管 AVE 方法引入了更多的句子信息，但由于它将每个句子赋予同等的权重，它也会从错误标注的语句中得到负面的噪音信息，从而损害关系抽取的性能。（4）对于 CNN 和 PCNN，与包括 AVE 方法在内的其他方法相比，ATT 方法在整个召回范围内实现了最高的精度。它表明，所提出的选择性注意力机制是有益的。它可以有效地滤除无意义的句子，有效解决基于远程监督的关系抽取中的错误标注问题。

表 A-2 对于拥有不同句子数目的实体对的关系抽取方法的 P@N 指标。

Test Settings	One				Two				All			
P@N(%)	100	200	300	Mean	100	200	300	Mean	100	200	300	Mean
CNN+ONE	68.3	60.7	53.8	60.9	70.3	62.7	55.8	62.9	67.3	64.7	58.1	63.4
+AVE	75.2	67.2	58.8	67.1	68.3	63.2	60.5	64.0	64.4	60.2	60.1	60.4
+ATT	76.2	65.2	60.8	67.4	76.2	65.7	62.1	68.0	76.2	68.6	59.8	68.2
PCNN+ONE	73.3	64.8	56.8	65.0	70.3	67.2	63.1	66.9	72.3	69.7	64.1	68.7
+AVE	71.3	63.7	57.8	64.3	73.3	65.2	62.1	66.9	73.3	66.7	62.8	67.6
+ATT	73.3	69.2	60.8	67.8	77.2	71.6	66.1	71.6	76.2	73.1	67.4	72.2

A.4.4 语句数量的影响

在原始测试数据集中，有 74,857 个实体对仅对应于一个句子，在所有实体对上占的比例近 3/4。由于我们选择性注意力模型的优势在于处理包含多个句子的实体对的情况，所以我们比较了 CNN/PCNN+ONE，CNN/PCNN+AVE 和 CNN/PCNN+ATT 在具有多个句子的实体对集合上的表现。然后我们在三个测试设置下检查这三种方法：

- **One:** 对于每个测试实体对，我们随机选择其对应的句子集合中的一句话，并将这句话用作关系预测。
- **Two:** 对于每个测试实体对，我们随机选择其对应的句子集合中的两句话，并将这两句话用作关系预测。
- **All:** 对于每个测试实体对，我们使用其对应的句子集合中的所有句子进行关系预测。

值得注意的是，我们在训练过程中，使用了所有句子。我们将会汇报 P@100, P@200, P@300 这些数值指标以及他们的平均值。

表A-2展示了所有模型在三种设置下的 P@N 指标。从这个表中，我们可以观察到：（1）对于 CNN 和 PCNN，ATT 方法在所有测试设置中均达到最佳性能。它表明了句子级选择性注意力机制对于多实例学习的有效性。（2）对于 CNN 和 PCNN，AVE 方法在 One 测试设置下，效果与 ATT 方法相当。然而，当每个实体对的测试句子数量增加时，AVE 方法的性能几乎没有改善。随着句数增加，它甚至在 P@100, P@200 中逐渐下降。原因在于，由于我们将每个句子同等地看待，句子中包含的不表达任何关系的噪音数据对于关系抽取的表现会产生负面影响。（3）在 ONE 测试设置下，CNN+AVE 和 CNN+ATT 与 CNN+ONE 相比有 5 到 8 个百分点的改进。由于每个实体对在这个测试设置中只有一个句子，这些方法的唯一区别是来自训练。因此，它表明利用所有的句子会带来更多的信息，尽管它也可能带来一些额外的噪音。（4）对于 CNN 和 PCNN，ATT 方法在 Two 和 All 测试设置下优于其他两个基线 5 到 9 个百分点。它表明，通过考虑更多有用的信息，CNN + ATT 排名较高的关系事实更可靠，有利于关系抽取。

A.4.5 与基于人工特征的方法的比较

为了验证我们所提出的方法，我们选择了以下三种基于人工特征的方法来进行性能比较：**Mintz**^[4] 是一个传统的基于远程监督的模型。

MultiR^[6] 提出了一个概率图模型用于多实例学习，它的特点在于可以处理

关系类型之间的重合。

MIML^[7] 同时考虑了多实例和多关系类型两种情况（即每个实体对可能有多个句子，也可能有多个关系类型）。

我们通过这些作者发布的代码，实现了这些模型。

图A-4中展示了每个方法的准确率-召回率曲线。我们可以观察得到：（1）在整个召回率范围内，CNN / PCNN + ATT 显著的优于所有基于人工特征的方法。当召回率大于 0.1 时，基于特征的方法的性能迅速下降。相比之下，在召回率达到约 0.3 之前，我们的模型都具有合理的准确率。这表明人工设计的特征不能简洁地表达句子的语义含义，而 NLP 工具带来的错误必然会损害关系抽取的性能。相比之下，可以自主学习每个句子的向量表示的 CNN / PCNN + ATT 可以很好地表达每个句子。（2）在整个召回率范围内，PCNN + ATT 与 CNN + ATT 相比表现要好得多。这意味着选择性注意力机制可以很好地考虑所有句子的全局信息，但无法使模型对于单个句子的理解和表示变好。因此，如果有更好的句子编码器，我们模型的性能可以进一步提高。

A.4.6 案例分析

表A-3展示了测试集中两个选择性注意力机制的例子。对于每个关系，我们展示了对应的拥有高注意力权值的句子和拥有低注意力权值的句子。而且我们将每个实体对都进行了加粗显示。

通过这个表格，我们可以发现：第一个例子是与关系 `employer_of` 相关的。拥有低注意力权值的句子并没有很好地表达两个实体间的关系，然而高注意力权值对应的句子可以很好地表达 *Mel Karmazin* 是 *Sirius Satellite Radio* 的首席执行官。第二个例子是与关系 `place_of_birth` 相关。拥有低注意力权值的句子表达了 *Ernst Haefliger* 趋势在哪里，而不是像高注意力权值句子所表达的他出生在哪里。

A.5 结论与未来工作

在本文中，我们提出了基于语句级别选择性注意力记住的卷积神经网络模型。我们的模型可以充分利用所有的包含有用信息的句子，在一定程度上解决远程监督给关系抽取带来的错误标注问题。在实验中，我们评估我们的关系抽取模型。实验结果表明，相比于目前最先进的基于人工特征的方法和神经网络方法，我们的方法有着显著而一致的性能提升。

表 A-3 NYT 语料上选择性注意力机制的例子。

Relation	employer_of
Low	When Howard Stern was preparing to take his talk show to Sirius Satellite Radio , following his former boss, Mel Karmazin , Mr. Hollander argued that ...
High	Mel Karmazin , the chief executive of Sirius Satellite Radio , made a lot of phone calls ...
Relation	place_of_birth
Low	Ernst Haefliger , a Swiss tenor who ... roles , died on Saturday in Davos , Switzerland, where he maintained a second home.
High	Ernst Haefliger was born in Davos on July 6, 1919, and studied at the Wettinger Seminary ...

在未来，我们的工作会朝如下几个目标进行：

- 我们的模型通过实例级选择性注意力机制将多实例学习与神经网络结合在一起。它不仅可以用于远程监督关系提取，还可以用于其他多实例学习任务。我们将在文本分类等其他领域继续探索我们的模型。
- 卷积神经网络是神经关系抽取的有效神经网络之一。研究人员还为关系提取提出了许多其他神经网络模型。将来，我们将把实例级选择性注意力机制与这些关系抽取模型相结合，得到更好的关系抽取系统。

致谢

这项工作由如下资金所支持：国家 973 项目 (No. 2014CB340501)，中国自然科学基金委员会 (NSFC No. 61572273,61303075) 和清华大学创新性科学研究项目 (20151080406)。





图 A-3 上方: CNN, CNN+ONE, CNN+AVE, CNN+ATT 模型的准确率-召回率曲线。下方: PCNN, PCNN+ONE, PCNN+AVE, PCNN+ATT 模型的准确率-召回率曲线。




图 A-4 与基于人工特征的方法的性能比较。

参考文献

- [1] Bollacker K, Evans C, Paritosh P, et al. Freebase: a collaboratively created graph database for structuring human knowledge[C]//Proceedings of KDD. [S.l.: s.n.], 2008: 1247-1250.
- [2] Auer S, Bizer C, Kobilarov G, et al. Dbpedia: A nucleus for a web of open data[M]. [S.l.: Springer, 2007
- [3] Suchanek F M, Kasneci G, Weikum G. Yago: a core of semantic knowledge[C]//Proceedings of WWW. [S.l.]: ACM, 2007: 697-706.
- [4] Mintz M, Bills S, Snow R, et al. Distant supervision for relation extraction without labeled data[C]//Proceedings of ACL-IJCNLP. [S.l.: s.n.], 2009: 1003-1011.
- [5] Riedel S, Yao L, McCallum A. Modeling relations and their mentions without labeled text [M]//Proceedings of ECML-PKDD. [S.l.: s.n.], 2010: 148-163
- [6] Hoffmann R, Zhang C, Ling X, et al. Knowledge-based weak supervision for information extraction of overlapping relations[C]//Proceedings of ACL-HLT. [S.l.: s.n.], 2011: 541-550.
- [7] Surdeanu M, Tibshirani J, Nallapati R, et al. Multi-instance multi-label learning for relation extraction[C]//Proceedings of EMNLP. [S.l.: s.n.], 2012: 455-465.
- [8] Socher R, Huval B, Manning C D, et al. Semantic compositionality through recursive matrix-vector spaces[C]//Proceedings of EMNLP-CoNLL. [S.l.: s.n.], 2012: 1201-1211.
- [9] Zeng D, Liu K, Lai S, et al. Relation classification via convolutional deep neural network[C]//Proceedings of COLING. [S.l.: s.n.], 2014: 2335-2344.
- [10] dos Santos C N, Xiang B, Zhou B. Classifying relations by ranking with convolutional neural networks[C]//Proceedings of ACL: volume 1. [S.l.: s.n.], 2015: 626-634.
- [11] Zeng D, Liu K, Chen Y, et al. Distant supervision for relation extraction via piecewise convolutional neural networks[C]//Proceedings of EMNLP. [S.l.: s.n.], 2015.
- [12] Bunescu R, Mooney R. Learning to extract relations from the web using minimal supervision [C]//Proceedings of ACL: volume 45. [S.l.: s.n.], 2007: 576.
- [13] Bengio Y. Learning deep architectures for ai[J]. Foundations and trends® in Machine Learning, 2009, 2(1): 1-127.
- [14] Collobert R, Weston J, Bottou L, et al. Natural language processing (almost) from scratch[J]. JMLR, 2011, 12: 2493-2537.
- [15] dos Santos C N, Gatti M. Deep convolutional neural networks for sentiment analysis of short texts[C]//Proceedings of COLING. [S.l.: s.n.], 2014.
- [16] Socher R, Bauer J, Manning C D, et al. Parsing with compositional vector grammars[C]//Proceedings of ACL. [S.l.]: Citeseer, 2013.

- [17] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[C]// Proceedings of NIPS. [S.l.: s.n.], 2014: 3104-3112.
- [18] Xie R, Liu Z, Jia J, et al. Representation learning of knowledge graphs with entity descriptions [Z]. [S.l.: s.n.], 2016.
- [19] Mnih V, Heess N, Graves A, et al. Recurrent models of visual attention[C]//Proceedings of NIPS. [S.l.: s.n.], 2014: 2204-2212.
- [20] Chorowski J, Bahdanau D, Cho K, et al. End-to-end continuous speech recognition using attention-based recurrent nn: first results[J]. arXiv preprint arXiv:1412.1602, 2014.
- [21] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention[J]. Proceedings of ICML, 2015.
- [22] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [23] Finkel J R, Grenager T, Manning C. Incorporating non-local information into information extraction systems by gibbs sampling[C]//Proceedings of ACL. [S.l.]: Association for Computational Linguistics, 2005: 363-370.